

存储论

概率与随机系统建模

刘铠鸣

厦门大学

2025 年 7 月 31 日

今天学什么？

- 什么是库存管理？
- 为什么需要控制库存？
- 经典 EOQ 模型
- 现实中的调整
- 超市案例练习

生活中的库存问题

场景 1 - 奶茶店

- 每天需要 100 杯原料
- 每次订货费 50 元
- 每杯每天存储成本 0.1 元
- 问：每周订几次货？每次订多少？

场景 2 - 文具店

- 笔记本月销 300 本
- 供应商每次送货收 80 元
- 每本每月存仓费 2 元
- 问：怎样订货最省钱？

三个关键成本

成本类型	说明	示例
订购成本	每次下单固定费用	快递费、人工费
持有成本	保管库存的费用	仓库租金、保险费
缺货成本	库存不足的损失	客户流失、紧急采购

小思考

外卖餐厅的”预制菜”属于哪种成本优化？

库存变化示意图

典型模式

- 进货 $\rightarrow$ 消耗 $\rightarrow$ 再进货
- 平均库存 = 最大库存/2

例

手机店每月卖出 200 台，每次进货 400 台：

- 平均库存 = $400/2 = 200$ 台
- 每月周转次数 = $200/400 = 0.5$ 次

经济订货批量公式

最简单情况

$$Q^* = \sqrt{\frac{2 \times \text{年需求} \times \text{订货费}}{\text{存储费}}}$$

例

年需求 1200 件，每次订货费 30 元，每件年存储费 4 元：

$$Q^* = \sqrt{\frac{2 \times 1200 \times 30}{4}} = 134 \text{件}$$

服装店案例

- 牛仔裤年销量 2400 条
- 每次采购订单处理费 100 元
- 每条裤子年仓储成本 6 元

- ① 计算最优订货量
- ② 计算每年订货次数
- ③ 计算总库存成本

服装店案例

- 牛仔裤年销量 2400 条
- 每次采购订单处理费 100 元
- 每条裤子年仓储成本 6 元

- ① 计算最优订货量
- ② 计算每年订货次数
- ③ 计算总库存成本

答案

$Q^* = 283$ 条, 年订货 8.5 次, 总成本 \$1697

EOQ 使用注意事项

- 适用场景：

- 需求稳定可预测
- 订货提前期固定
- 单位成本不变

- 常见错误：

- 忽略季节波动
- 低估实际存储成本
- 忽视最小起订量

例

冰淇淋店冬季直接套用夏季 EOQ 会导致库存积压

有数量折扣时怎么办？

打印机耗材案例

订货量	单价
1-99	\$50
100-499	\$45
500+	\$40

计算步骤：

- ① 计算各区间 EOQ
- ② 检查 EOQ 是否在区间内
- ③ 计算各有效点总成本
- ④ 选择最低成本方案

允许缺货的情况

关键改变

可以临时缺货，但会产生信誉损失

例

- 原 EOQ: 200 单位
- 缺货成本 = \$10/单位
- 新 EOQ: $\sqrt{\frac{2 \times 1200 \times 30}{4}} \times \frac{4+10}{10} = 251$ 单位
- 允许最大缺货量 = 72 单位

报童问题日报案例

- 每份进价 1 元，售价 3 元
- 未卖出回收价 0.5 元
- 最优服务水平 = $\frac{3-1}{(3-1)+(1-0.5)} = 80\%$
- 应准备多少份？

历史销量	概率
100	20%
150	50%
200	30%

报童问题日报案例

- 每份进价 1 元，售价 3 元
- 未卖出回收价 0.5 元
- 最优服务水平 = $\frac{3-1}{(3-1)+(1-0.5)} = 80\%$
- 应准备多少份？

历史销量	概率
100	20%
150	50%
200	30%

答案：选择 150 份（累计概率 70% 最接近 80

安全库存计算

防波动储备

安全库存 = 安全系数 × 需求波动

- 日需求均值 100, 标准差 20
- 95
- 安全库存 = 1.65×20 33 单位

例

药店常用药品的安全库存设置

- **丰田生产方式：**
 - 按需生产
 - 小批量高频次
 - 供应商协同
- **适用条件：**
 - 稳定高质量供应链
 - 精准需求预测
 - 快速响应能力

思考

为什么医院血库不能完全零库存？

ABC 分类法

A 类物品 (20%):

- 占 70% 价值
- 严格管控
- 小批量多频次

C 类物品 (50%):

- 占 5% 价值
- 简化管理
- 大批量少频次

例

电子厂的芯片 (A) vs 螺丝钉 (C)

给定数据

- 年销量：矿泉水 36000 箱
- 订货费：每次 \$200
- 存储费：\$1.5/箱/年
- 缺货成本：\$0.8/箱
- 供应商要求最小订单 500 箱

小组讨论：

- ① 计算理论 EOQ
- ② 考虑最小订单量
- ③ 评估允许缺货方案
- ④ 提出最终建议

- 关键公式: $EOQ = \sqrt{\frac{2DC_o}{C_h}}$
- 实际调整比理论更重要
- 随机需求需要安全库存
- 不同物品采用不同策略

课后作业

计算自己每月生活费的最优”采购策略”

排队现象无处不在

- **日常生活：**
 - 超市收银台
 - 银行窗口
 - 餐厅等位
- **工业生产：**
 - 生产线调度
 - 仓储物流
- **信息技术：**
 - 网络数据包传输
 - 服务器请求处理

核心问题

如何在服务资源和用户需求间取得平衡？

历史里程碑

- 1909 年 - 丹麦工程师 A.K. Erlang 研究电话交换系统
- 1950 年代 - D.G. Kendall 建立标准化表示法
- 1960 年代 - 排队网络理论发展
- 21 世纪 - 应用于云计算、共享经济等领域

Kendall 表示法

标准表示: $A/B/C/D/E/F$

- A - 到达时间间隔分布
- B - 服务时间分布
- C - 服务台数量
- D - 系统容量
- E - 顾客源规模
- F - 排队规则

例

常见模型

- $M/M/1$: 泊松到达、指数服务、单服务台
- $M/G/3$: 泊松到达、一般服务、3 个服务台
- $D/M/2/K$: 确定型到达、指数服务、2 服务台、容量 K

基本假设

- 泊松到达过程 (λ 为到达率)
- 指数服务时间 (μ 为服务率)
- 单服务台
- 无限队列容量
- 无限顾客源
- FIFO 服务规则

关键性能指标

- 系统利用率: $\rho = \frac{\lambda}{\mu}$ (要求 $\rho < 1$)
- 平均队列长度: $L_q = \frac{\rho^2}{1-\rho}$
- 平均等待时间: $W_q = \frac{L_q}{\lambda}$

例

银行柜台服务

- 平均每 5 分钟到达 1 位顾客 ($\lambda = 12$ 人/小时)
- 平均服务时间 4 分钟 ($\mu = 15$ 人/小时)
- 计算性能指标:

$$\rho = \frac{12}{15} = 0.8$$

$$L = \frac{\rho}{1 - \rho} = 4 \text{人}$$

$$L_q = \frac{\rho^2}{1 - \rho} = 3.2 \text{人}$$

$$W = \frac{1}{\mu - \lambda} = 0.333 \text{小时} = 20 \text{分钟}$$

M/M/c 模型

多服务台系统

- c 个相同服务台
- 共享队列
- 系统利用率: $\rho = \frac{\lambda}{c\mu}$
- 稳态条件: $\rho < 1$

Erlang C 公式

顾客需要等待的概率:

$$P_{wait} = \frac{(c\rho)^c}{c!(1-\rho)} \cdot \left[\sum_{k=0}^{c-1} \frac{(c\rho)^k}{k!} + \frac{(c\rho)^c}{c!(1-\rho)} \right]^{-1}$$




图: M/M/c 系统


排队网络

基本类型

- 开环网络：外部到达，最终离开
- 闭环网络：固定数量顾客循环
- 混合网络：开环与闭环结合

例

医院急诊流程



图：急诊科排队网络

非马尔可夫模型

G/G/1 近似

- 一般到达和服务分布
- Kingman 近似公式:

$$W_q \approx \left(\frac{c_a^2 + c_s^2}{2} \right) \left(\frac{\rho}{1 - \rho} \right) \frac{1}{\mu}$$

其中 c_a, c_s 为到达和服务时间的变异系数

例

生产线调度

- 零件到达时间变异系数 $c_a = 1.2$
- 加工时间变异系数 $c_s = 0.8$
- $\rho = 0.7, \mu = 10$ 件/小时
- 计算平均等待时间:

呼叫中心优化

问题描述


- 平均每小时 300 通电话
- 平均通话时间 3 分钟
- 服务水平目标：80% 电话 20 秒内接听

计算过程

- $\lambda = 300, \mu = 20$
- 使用 Erlang C 公式计算所需坐席数
- 通过迭代求得最少需要 17 个坐席

弹性伸缩策略

- 请求到达率随时间变化
- 动态调整虚拟机数量
- 目标：平衡响应时间和资源成本



图：动态资源调整

排队论建模五步法

- ① 问题识别：确定系统的排队特征
- ② 模型选择：根据 Kendall 表示法确定模型类型
- ③ 参数估计：收集数据估计 λ, μ 等参数
- ④ 性能分析：计算关键指标 (L, W, ρ 等)
- ⑤ 优化建议：基于分析提出改进方案

建模要点

- 明确系统的边界和假设条件
- 区分瞬态分析和稳态分析
- 验证模型假设的合理性（如泊松性检验）

典型建模工具

分析工具：

- 马尔可夫链分析
- 生灭过程理论
- Little 公式： $L = \lambda W$
- 排队网络近似算法

仿真工具：

- MATLAB Queueing Toolbox
- Python SimPy 库
- AnyLogic 可视化仿真
- Arena 专业仿真软件

工具选择建议


- 简单系统：解析解优先
- 复杂系统：仿真 + 解析结合

案例 1：医院急诊科资源配置 (M/M/c+K 模型)

问题描述

某三甲医院急诊科：

- 平均每小时到达 12 名患者
- 医生处理时间平均 30 分钟
- 现有 5 个诊室
- 候诊区最多容纳 15 人
- 目标：患者平均等待时间 < 45 分钟



建模关键

考虑患者因队列过长而流失（有限容量 $K=15+5$ ）

医院急诊科模型求解

参数设定

- $\lambda = 12/h$, $\mu = 2/h$
- $c = 5$, $K = 20$
- 流失概率公式:

$$P_{loss} = \frac{(c\rho)^K / c!}{\sum_{k=0}^K (c\rho)^k / k!}$$

例


计算结果

- 实际接受率: $\lambda_{eff} = 11.2/h$ (考虑流失)
- 平均等待时间: $W_q = 38$ 分钟 (达标)
- 医生利用率: $\rho = 0.89$
- 建议: 当 $\lambda > 14$ 时需增加临时诊室

案例 2：快递分拣中心优化（排队网络）

系统描述

- 到达区 (M/M/1): $\lambda = 1200$ 件/h
- 初筛站 (M/M/3): $\mu = 600$ 件/h
- 细分站 A (M/M/2): 概率 0.6
- 细分站 B (M/M/2): 概率 0.4



优化目标

在预算约束下最小化平均处理时间

决策变量

- 初筛站服务台数量 (3-5 个)
- 细分站服务台配比 (2+2 或 3+1)

快递分拣中心求解

Jackson 网络解法

- ① 计算各节点有效到达率
- ② 分解为独立子系统
- ③ 应用 Little 公式

例

最优配置

- 初筛站：4 台 (\$80 万)
- 细分站：3+1 配置 (\$70 万)
- 总处理时间：8.2 分钟


案例 3：共享单车调度（闭环排队系统）

问题特征

- 固定数量的单车在站点间流动
- 用户到达服从空间非均匀泊松过程
- 站点容量限制导致的“无车可借”问题

模型创新点

- 结合马尔可夫决策过程
- 引入调度车路径优化



性能指标

用户平均等待时间 + 调度车运营成本

“同心协力”策略分析

- 实际问题：多人协作的队列效率优化
- 排队论视角：多服务台协同工作系统
- 关键参数：协作效率衰减因子

解题思路

- ① 建立 $M/M/c$ 状态相关服务率模型
- ② 引入团队协作效率函数
- ③ 计算最优团队规模 ($c=5$ 时最佳)

优秀论文必备要素

- 清晰的模型假设
 - 明确说明泊松到达假设的合理性
- 完整的参数说明
 - 给出 λ, μ 的估计方法
- 模型的灵敏度分析
 - 考察参数变化对结果的影响

例

常见错误

- 忽略系统容量限制
- 未验证稳态条件 ($\rho < 1$)
- 混淆平均等待时间 W_q 与平均逗留时间 W

当前热点

- **机器学习 + 排队论：**
 - 用强化学习优化排队策略
 - 深度学习预测到达模式
- **共享经济模型：**
 - 网约车匹配问题
 - 共享单车调度
- **医疗资源调度：**
 - 急诊科病床分配
 - 手术室排程

参考文献与扩展阅读

-  Gross D., et al. *Fundamentals of Queueing Theory*, 5th Ed. Wiley, 2018
-  Serfozo R. *Basics of Applied Stochastic Processes*. Springer, 2009
-  Koole G. *Call Center Optimization*. MG Books, 2013
-  Sutton R.S., Barto A.G. *Reinforcement Learning: An Introduction*. MIT Press, 2018

推荐资源

- 在线课程：Coursera "Operations Research"
- 仿真工具：AnyLogic, SimPy
- 开源库：Python 的 QueueingToolkit

谢谢！ 问题与讨论