



回归相关数据处理

数据处理方法

谭忠

厦门大学

2026 年 7 月 30 日



廈門大學 数学科学学院
SCHOOL OF MATHEMATICAL SCIENCES XIAMEN UNIVERSITY

- 统计基础
 - 统计基础知识
 - 参数估计
- 假设检验
 - 分布已知的假设检验
 - 分布未知的假设检验-卡方检验
- 回归分析
 - 一元线性回归
 - 多元线性回归



- 方差分析
 - 单因素方差分析
 - 双因素方差分析
- 案例分析
- 作业



位置统计量

- 均值: $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$
- 顺序统计量: $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$
- 中位数: $m_e = \begin{cases} x_{(\frac{n+1}{2})} & \text{当 } n \text{ 为奇数时} \\ \frac{1}{2}(x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}) & \text{当 } n \text{ 为偶数时} \end{cases}$
- 百分位数: $m_p = \begin{cases} x_{(|np|+1)} & \text{当 } np \text{ 不是整数时} \\ \frac{1}{2}(x_{(np)} + x_{(np+1)}) & \text{当 } np \text{ 是整数时} \end{cases}$



分散程度度量

- 样本方差: $s^{*2} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$, $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$
- 样本标准差: $s^* = \sqrt{s^{*2}}$, $s = \sqrt{s^2}$
- 变异系数: $CV = \frac{s}{\bar{x}} \times 100\%$
- 极差: $R = x_{(n)} - x_{(1)} = \max(x) - \min(x)$
- 样本标准误差: $s_m = \sqrt{\frac{1}{n(n-1)} \sum_{i=1}^n (x_i - \bar{x})^2} = \frac{s}{\sqrt{n}}$



分布形状度量

- K 阶原点矩: $a_k = \frac{1}{n} \sum_{i=1}^n x_i^k$
- K 阶中心矩: $b_k = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^k$
- 样本偏度: $r_1 = \frac{b_3}{b_2^{3/2}}$

刻画数据的对称性指标, 关于均值对称则偏度为 0.

- 样本峰度: $r_2 = \frac{b_4}{b_2^2} - 3$

反映总体分布密度曲线在其峰值附近的陡峭程度.



重要的概率分布

- 正态分布 $N(\mu, \sigma^2)$: $N(0, 1)$ 为标准正态分布
- 若 $X_1, X_2, \dots, X_n$ 为标准正态分布, 那么 $\sum_{i=1}^n x_i^2$ 服从卡方分布 $\chi^2(n)$
 $\frac{X_1}{\sqrt{\chi^2/n}}$ 服从 t 分布 $t(n)$
若 $S_1^2 \sim \chi^2(n), S_2^2 \sim \chi^2(m)$, 则 $\frac{S_1^2/n}{S_2^2/m}$ 服从 F 分布 $F(m, n)$



统计量分布

单个正态总体情形 $X \sim N(\mu, \sigma^2)$

则：

$$\bar{x} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

$$\frac{\bar{x} - \mu}{S/\sqrt{n}} \sim t(n-1)$$



统计量分布

两个正态总体情形 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$

则:

- $$\frac{(\bar{x} - \mu_1) - (\bar{y} - \mu_2)}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}} \sim N(0, 1)$$

- $$\frac{(\bar{x} - \mu_1) - (\bar{y} - \mu_2)}{S/\sqrt{1/n_1 + 1/n_2}} \sim t(n_1 + n_2 - 2)$$

其中

$$S = \sqrt{\frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}}$$

- $$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$$

参数估计-点估计

点估计

设 $x_1, x_2, \dots, x_n$ 是来自于同一个样本, 用于估计未知参数 θ 的统计量 $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$ 称为 θ 的估计量, 或称为 θ 的点估计

点估计常用方法

- 矩估计:

$$EX^k = \frac{1}{n} \sum_{i=1}^n x_i^k$$

- 极大似然估计:

$$\hat{\theta} : L(\theta) = \sup_{\theta \in \Theta} \prod_{i=1}^n f(x_i; \theta)$$



参数估计-点估计

估计方法评价标准

评价估计优劣的标准有无偏性、有效性、一致性（相合性）等

- 无偏性：

$$E\hat{\theta} = \theta$$

- 有效性：对无偏估计量 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ ，若

$$D\hat{\theta}_1 \leq D\hat{\theta}_2$$

则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效。

- 一致性：

$$\forall \varepsilon > 0, \lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| > \varepsilon) = 0$$

等价于

$$\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta, \quad \lim_{n \rightarrow \infty} D(\hat{\theta}_n) = 0$$

参数估计-区间估计

区间估计

- 当 $P(\hat{\theta}_1 < \theta < \hat{\theta}_2) = 1 - \alpha$ 时, 称 $[\hat{\theta}_1, \hat{\theta}_2]$ 为参数 θ 水平为 $1 - \alpha$ 的置信区间。

单个正态分布

- 设单个正态总体情形 $X \sim N(\mu, \sigma^2)$, μ 的双侧置信区间:
 - 方差 σ^2 已知:

$$\left[\bar{x} - \mu_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}, \bar{x} + \mu_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \right]$$

- 方差 σ^2 未知:

$$\left[\bar{x} - \frac{s}{\sqrt{n}} t_{1-\alpha/2}(n-1), \bar{x} + \frac{s}{\sqrt{n}} t_{1-\alpha/2}(n-1) \right]$$

单个正态分布

- 单个正态总体情形 $X \sim N(\mu, \sigma^2)$, σ^2 的双侧置信区间:

- 均值 μ 已知:

$$\left[\frac{\sum_{i=1}^n (x_i - \mu)^2}{\chi_{\alpha/2}^2(n)}, \frac{\sum_{i=1}^n (x_i - \mu)^2}{\chi_{1-\alpha/2}^2(n)} \right]$$

- 均值 μ 未知:

$$\left[\frac{(n-1)s^2}{\chi_{\alpha/2}^2(n-1)}, \frac{(n-1)s^2}{\chi_{1-\alpha/2}^2(n-1)} \right]$$



参数估计-区间估计

两个正态分布

两个正态总体情形 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$

- 方差 σ_1^2, σ_2^2 均已知时, $\mu_1 - \mu_2$ 的置信区间:

$$((\bar{x} - \mu_1) - (\bar{y} - \mu_2) - \mu_{1-\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, (\bar{x} - \mu_1) - (\bar{y} - \mu_2) + \mu_{1-\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}})$$

- 方差均未知但是相等时, $\mu_1 - \mu_2$ 的置信区间:

$$((\bar{x} - \mu_1) - (\bar{y} - \mu_2) - t_{1-\alpha/2}(n_1 + n_2 - 2) \cdot S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}, (\bar{x} - \mu_1) - (\bar{y} - \mu_2) + t_{1-\alpha/2}(n_1 + n_2 - 2) \cdot S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}})$$

其中

$$S_w^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$$

参数估计-区间估计

两个正态分布

- μ_1, μ_2 均已知时, 方差比 σ_1^2/σ_2^2 的置信区间::

$$\left(\frac{\sum_{i=1}^{n_1} (x_i - \mu_1)^2 / n_1}{\sum_{i=1}^{n_2} (y_i - \mu_2)^2 / n_2} \cdot \frac{1}{F_{\alpha/2}(n_1, n_2)}, \frac{\sum_{i=1}^{n_1} (x_i - \mu_1)^2 / n_1}{\sum_{i=1}^{n_2} (y_i - \mu_2)^2 / n_2} \cdot F_{1-\alpha/2}(n_2, n_1) \right)$$

- μ_1, μ_2 均未知时, 方差比 σ_1^2/σ_2^2 的置信区间::

$$\left(\frac{s_1^2}{s_2^2} \cdot \frac{1}{F_{\alpha/2}(n_1 - 1, n_2 - 1)}, \frac{s_1^2}{s_2^2} \cdot F_{1-\alpha/2}(n_1 - 1, n_2 - 1) \right)$$

分布已知的假设检验

1、单个正态总体均值检验

单个正态总体均值检验

右侧检验：

$$H_0 : \mu \leq \mu_0, \quad H_1 : \mu > \mu_0$$

左侧检验：

$$H_0 : \mu \geq \mu_0, \quad H_1 : \mu < \mu_0$$

双侧检验：

$$H_0 : \mu = \mu_0, \quad H_1 : \mu \neq \mu_0$$



分布已知的假设检验

1、单个正态总体均值检验

u 检验 (σ 已知)

检验统计量：

$$u = \frac{\bar{x} - \mu_0}{\sigma / \sqrt{n}}$$

三种情形：

- ❶ 拒绝域 $\{u \geq u_{1-\alpha}\}$, p 值 $1 - \Phi(u_0)$
- ❷ 拒绝域 $\{u \leq u_\alpha\}$, p 值 $\Phi(u_0)$
- ❸ 拒绝域 $\{|u| \geq u_{1-\alpha/2}\}$, p 值 $2(1 - \Phi(|u_0|))$



分布已知的假设检验

1、单个正态总体均值检验

t 检验 (σ 未知)

检验统计量：

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

三种情形：

- ❶ 拒绝域 $\{t \geq t_{1-\alpha}(n-1)\}$, p 值 $P(t \geq t_0)$
- ❷ 拒绝域 $\{t \leq t_{\alpha}(n-1)\}$, p 值 $P(t \leq t_0)$
- ❸ 拒绝域 $\{|t| \geq t_{1-\alpha/2}(n-1)\}$, p 值 $P(|t| \geq |t_0|)$



分布已知的假设检验

1、单个正态总体均值检验

Matlab 函数说明

- `[h,p,ci]=ztest(x,mu,sigma,alpha,tail)`

参数说明:

- `tail` 取值: 0 (缺省)、1、-1, 分别对应三种备选假设之一
- 输出参数:
 - $h = 0$ 表示接受 H_0
 - $h = 1$ 表示拒绝 H_0
 - p 表示拒绝原假设 H_0 的最小显著性水平 (p 越小 H_0 越值得怀疑)
 - ci 是 μ_0 的置信区间
- 当 σ^2 未知时, 均值 μ 的检验使用:

`[h,p,ci]=ttest(x,mu,alpha,tail)`



分布已知的假设检验

1、单个正态总体均值检验

例

某车间用一台包装机包装糖果. 包的袋装糖重是一个随机变量, 服从正态分布. 当机器正常时, 其均值为 0.5 公斤, 标准差为 0.015 公斤. 某日开工后为检验包装机是否正常, 随机地抽取它所包装的糖 9 袋, 称得净重为 (公斤):

0.497, 0.506, 0.518, 0.524, 0.498, 0.511, 0.520, 0.515, 0.512.

问机器是否正常?

即假设检验设定: $x \sim N(\mu, 0.015^2)$

原假设: $H_0: \mu = \mu_0 = 0.5$

备择假设: $H_1: \mu \neq 0.5$



分布已知的假设检验

1、单个正态总体均值检验

解

Matlab 实现如下:

```
x=[ 0.497 0.506 0.518 0.524 0.498 0.511 0.520 0.515 0.512 ];
```

```
[h,p,ci]=ztest(x,0.5,0.015)
```

求得 $h=1$, $p=0.0248$, $ci=[0.5014 \ 0.5210]$

在 0.05 水平下可拒绝原假设, 即认为这天包装机工作不正常.



分布已知的假设检验

1、单个正态总体均值检验

例

据调查，一组元件的寿命为：159, 280, 101, 212, 224, 379, 179, 264, 222, 362, 168, 250, 149, 260, 485, 170。已知该元件寿命符合正态分布，请问该元件的平均寿命是否大于 225 小时？

假设设定：

- 原假设 $H_0 : \mu \leq 225$
- 备择假设 $H_1 : \mu > 225$

解

σ^2 未知，均值 μ 的检验，Matlab 实现如下：

```
x=[159 280 101 212 224 379 179 264 222 362 168 250 149 260 485 170];
```

```
[h,p,ci]=ttest(x,225,0.05,1)
```

求得 $h=0$, $p=0.2570$, $ci=[198.2321 \text{ Inf}]$

说明在显著水平为 0.05 的情况下，不能拒绝原假设，认为元件的平均寿命不大于 225 小时。

分布已知的假设检验

2、两个正态总体均值检验

两个正态总体均值检验:

(显著性水平为 α)

检验法	条件	H_0	H_1	检验统计量	拒绝域
U 检验	σ_1, σ_2 已知	$\mu_1 \leq \mu_2$ $\mu_1 \geq \mu_2$ $\mu_1 = \mu_2$	$\mu_1 > \mu_2$ $\mu_1 < \mu_2$ $\mu_1 \neq \mu_2$	$U = \frac{X - Y}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}}$	$\{u \geq u_{1-\alpha}\}$ $\{u \leq u_\alpha\}$ $\{ u \geq u_{1-\frac{\alpha}{2}}\}$
t 检验	$\sigma_1 = \sigma_2 = \sigma$ 未知	$\mu_1 \leq \mu_2$ $\mu_1 \geq \mu_2$ $\mu_1 = \mu_2$	$\mu_1 > \mu_2$ $\mu_1 < \mu_2$ $\mu_1 \neq \mu_2$	$t = \frac{X - Y}{S_w \sqrt{\frac{1}{n} + \frac{1}{m}}}$	$\{t \geq t_{1-\alpha}(n+m-2)\}$ $\{t \leq t_\alpha(n+m-2)\}$ $\{ t \geq t_{1-\frac{\alpha}{2}}(n+m-2)\}$
近似 U 检验	σ_1, σ_2 未知 m, n 充分大	$\mu_1 \leq \mu_2$ $\mu_1 \geq \mu_2$ $\mu_1 = \mu_2$	$\mu_1 > \mu_2$ $\mu_1 < \mu_2$ $\mu_1 \neq \mu_2$	$U = \frac{X - Y}{\sqrt{\frac{S_X^2}{n} + \frac{S_Y^2}{m}}}$	$\{u \geq u_{1-\alpha}\}$ $\{u \leq u_\alpha\}$ $\{ u \geq u_{1-\frac{\alpha}{2}}\}$
近似 t 检验	σ_1, σ_2 未知 m, n 不太大	$\mu_1 \leq \mu_2$ $\mu_1 \geq \mu_2$ $\mu_1 = \mu_2$	$\mu_1 > \mu_2$ $\mu_1 < \mu_2$ $\mu_1 \neq \mu_2$	$t^* = \frac{X - Y}{\sqrt{\frac{S_X^2}{n} + \frac{S_Y^2}{m}}}$	$\{t^* \geq t_{1-\alpha}(l)\}$ $\{t^* \leq t_\alpha(l)\}$ $\{ t^* \geq t_{1-\frac{\alpha}{2}}(l)\}$

分布已知的假设检验

3、单个正态总体方差的检验

单个正态总体方差的检验:

(显著性水平为 α)

检验法	条件	H_0	H_1	检验统计量	拒绝域
χ^2 检验	μ 未知	$\sigma^2 \leq \sigma_0^2$ $\sigma^2 \geq \sigma_0^2$ $\sigma^2 = \sigma_0^2$	$\sigma^2 > \sigma_0^2$ $\sigma^2 < \sigma_0^2$ $\sigma^2 \neq \sigma_0^2$	$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2}$	$\{\chi^2 \geq \chi_{1-\alpha}^2(n-1)\}$ $\{\chi^2 \leq \chi_{\alpha}^2(n-1)\}$ $\{\chi^2 \leq \chi_{\alpha/2}^2(n-1)\}$ 或 $\chi^2 \geq \chi_{1-\frac{\alpha}{2}}^2(n-1)\}$



分布已知的假设检验

4、两个正态总体方差的检验

两个正态总体方差的检验:

(μ_1, μ_2 未知, 显著性水平为 α)

检验法	H_0	H_1	检验统计量	拒绝域
F 检验	$\sigma_1^2 \leq \sigma_2^2$	$\sigma_1^2 > \sigma_2^2$	$F = \frac{S_X^2}{S_Y^2}$	$\{F \geq F_{1-\alpha}(n-1, m-1)\}$
	$\sigma_1^2 \geq \sigma_2^2$	$\sigma_1^2 < \sigma_2^2$		$\{F \leq F_{\alpha}(n-1, m-1)\}$
	$\sigma_1^2 = \sigma_2^2$	$\sigma_1^2 \neq \sigma_2^2$		$\{F \leq F_{\frac{\alpha}{2}}(n-1, m-1)\}$ 或 $F \geq F_{1-\frac{\alpha}{2}}(n-1, m-1)\}$



分布已知的假设检验

例

为了比较两种谷物种子的优劣, 特选取 10 块土质不全相同的土地, 并将每块土地分为面积相同的两部分, 分别种植两种种子, 施肥与天健管理在 20 小块土地上都是一样, 下面是各小块上的单位产量:

土地	1	2	3	4	5	6	7	8	9	10
种子一的单位产量	23	35	29	42	39	29	37	34	35	28
种子二的单位产量	30	39	35	40	38	34	36	33	41	31



分布已知的假设检验

解

由于未知两个分布的方差，因此需要进行检验，统计量与拒绝域分别是：
统计量：

$$t_1 = \frac{\bar{x} - \bar{y}}{s_w / \sqrt{n/2}}$$

拒绝域：

$$W_1 = \{|t_1| > t_{1-\alpha/2}(2n-2)\}$$

其中 $s_w^2 = (s_x^2 + s_y^2) / 2$ ， α 是给定的显著性水平。

由给出的数据可算得：

$$\bar{x} = 33.1, \quad \bar{y} = 35.7, \quad s_x^2 = 33.2110, \quad s_y^2 = 14.2333, \quad s_w^2 = 23.7222,$$

从而可算得两样本的 t 检验统计量的值：

$$t_1 = \frac{33.1 - 35.7}{4.8705 / \sqrt{10/2}} = -1.1937$$

分布已知的假设检验

解

若给定 $\alpha = 0.05$, 查表得:

$$t_{0.975}(18) = 2.1009$$

由于 $|t_1| < 2.1009$, 故不应拒绝原假设, 即认为两种种子的单位产量平均值没有显著差别。

此处检验的 p 值为 0.2467。



分布已知的假设检验

matlab 代码

对于两个样本均值的检验，同样有函数 $[h,p,ci]=ttest2(x,y,alpha,tail)$
故上面的题目，可以通过 matlab 代码：

- $x=[25,35,29,42,39,29,37,34,35,28];$
- $y=[30,39,35,40,38,34,36,33,41,31];$
- $[h, p, ci] = ttest2(x, y, 0.05, 0)$

来进行计算，得到的结果为： $h = 0$

$p = 0.2641$



分布未知的假设检验——卡方检验

1、总体可以分为有限类，且总体分布不含未知参数

定义

设总体 X 可以分成 r 类，记为： $A_1, A_2, \dots, A_r$ ，如今要检验的假设为：

$$H_0 : P(A_i) = p_i, \quad i = 1, 2, \dots, r$$

其中各 p_i 已知， $p_i \geq 0$ 且 $\sum_{i=1}^r p_i = 1$,



分布未知的假设检验——卡方检验

1、总体可以分为有限类，且总体分布不含未知参数

统计量

现对总体 X 作了 n 次观察，各类出现的频数分别为 $n_1, n_2, \dots, n_r$ ，且 $\sum_{i=1}^r n_i = n$ 。

若 H_0 为真，则各概率 p_i 与频率 n_i/n 应相差不大，或各观察频数 n_i 与理论频数 np_i 应相差不大。因此提出如下统计量：

$$\chi^2 = \sum_{i=1}^r \frac{(n_i - np_i)^2}{np_i}$$

并指出，当样本容量 n 充分大且 H_0 为真时， χ^2 近似服从自由度为 $r-1$ 的 χ^2 分布。



分布未知的假设检验——卡方检验

1、总体可以分为有限类，且总体分布不含未知参数

拒绝域

从 χ^2 统计量的结构看，当 H_0 为真时，和式中每一项的分子 $(n_i - np_i)^2$ 都不应太大，从而总和也不会太大。若 χ^2 过大，人们就会认为原假设 H_0 不真。基于此想法，检验的拒绝域应有如下形式： $W = \{\chi^2 \geq c\}$
对于给定的显著性水平 α ，由分布 $\chi^2(r-1)$ 可定出 $c = \chi^2_{1-\alpha}(r-1)$



分布未知的假设检验——卡方检验

2、总体可以分为有限类，但总体分布含 k 个未知参数

在前面的基础之上，在总体分布中含有 k 个独立的未知参数时，若这 k 个参数用极大似然估计代替，则 p_i 用 $\hat{p}_i$ 代替，当样本容量 n 充分大时：

$$\chi^2 = \sum_{i=1}^r \frac{(n_i - n\hat{p}_i)^2}{n_i}$$

近似服从自由度为 $r - k - 1$ 的 χ^2 分布。



分布未知的假设检验——卡方检验

3、总体为连续分布的情况

定义

设样本 $X_1, X_2, \dots, X_n$ 为来自总体 X 的一个样本，要检验的假设是：

$$H_0 : X \text{ 服从分布 } F(x)$$

其中 $F(x)$ 中可以含有 k 个未知参数。若 $k = 0$ ，则 $F(x)$ 就完全已知。



分布未知的假设检验——卡方检验

3、总体为连续分布的情况

在这种情况下检验 H_0 的做法如下：检验 H_0 的做法如下：

- ① 把 X 的取值范围分成 r 个区间, 为确定起见, 不妨设为:

$$-\infty = a_0 < a_1 < a_2 < \cdots < a_{r-1} < a_r = \infty$$

$$\text{设各区间为: } A_1 = (a_0, a_1], \quad A_2 = (a_1, a_2], \quad \cdots, \quad A_{r-1} = (a_{r-2}, a_{r-1}], \quad A_r = (a_{r-1}, a_r]$$

- ② 统计样本落入这 r 个区间的频数, 分别记为 $n_1, n_2, \cdots, n_r$ 。这里要求各 $n_i \geq 5$ 。

- ③ 当 $k \neq 0$ 时, 对 k 个未知参数给出其极大似然估计, 记

$$p_i = P(a_{i-1} < X \leq a_i) = F(a_i) - F(a_{i-1})$$

从而用未知参数的极大似然估计代替后可算得各 $\hat{p}_i$ 。这样就把检验问题转化为分类数据的检验问题, 以后的计算同前面两个小节视未知参数个数 $k = 0$ 或 $k \neq 0$ 而定。



分布未知的假设检验——卡方检验

例

为研究混凝土抗压强度的分布，抽取了 200 件混凝土制件测定其抗压强度，经整理得频数分布表如下。试在 $\alpha = 0.05$ 水平上检验抗压强度的分布是否为正态分布。

抗压强度区间 $(a_{i-1}, a_i]$	频数 n_i
(190, 200)	10
(200, 210)	26
(210, 220)	56
(220, 230)	64
(230, 240)	30
(240, 250)	14
合计	200

分布未知的假设检验——卡方检验

解

若用 $F(x)$ 表示正态分布 $N(\mu, \sigma^2)$ 的分布函数, 则本例要检验假设:

H_0 : 抗压强度的分布为 $F(x)$

又由于 $F(x)$ 中含有两个未知参数 μ 与 σ^2 , 因而需用它们的极大似然估计去替代。这里仅给出了样本的分组数据, 因此只能用组中值 (即区间中点) 去代替原始数据, 然后求 μ 与 σ^2 的 MLE。

现在 6 个组中值分别为:

$x_1 = 195, \quad x_2 = 205, \quad x_3 = 215, \quad x_4 = 225, \quad x_5 = 235, \quad x_6 = 245$

均值估计:

$$\hat{\mu} = \bar{x} = \frac{1}{200} \sum_{i=1}^6 n_i x_i = 221$$

于是方差估计:

$$\hat{\sigma}^2 = s_n^2 = \frac{1}{200} \sum_{i=1}^6 n_i (x_i - \bar{x})^2 = 152, \quad \hat{\sigma} = s_n = \sqrt{152} = 12.33$$

分布未知的假设检验——卡方检验

解

在 $N(221, 152)$ 分布下, 求出落在区间 $(a_{i-1}, a_i]$ 的概率估计值:

$$p_i = \Phi\left(\frac{a_i - 221}{\sqrt{152}}\right) - \Phi\left(\frac{a_{i-1} - 221}{\sqrt{152}}\right), \quad i = 1, 2, \dots, r$$

不过常将 a_0 定为 $-\infty$, 将 a_r 定为 $+\infty$, 本例中 $r = 6$ 。

采用 $\chi^2 = \sum_{i=1}^r \frac{(n_i - n\hat{p}_i)^2}{n\hat{p}_i}$ 作为检验统计量, 在显著性水平 $\alpha = 0.05$, 自由度为 $r - k - 1 = 6 - 2 - 1 = 3$ 时, 查表得: $\chi_{0.95}^2(3) = 7.815$, 因此拒绝域为: $W = \{\chi^2 \geq 7.815\}$

由样本计算 χ^2 值的过程 (计算过程略) 可知 $\chi^2 = 1.332 < 7.815$ (临界值), 这表明样本落入接受域, 可接受抗压强度服从正态分布的假定。



分布未知的假设检验——卡方检验

卡方检验应用情况:

当题目中并不知道所给出的数据的分布, 且又明确告诉我们需要对数据分布进行研究是, 我们需要使用该方法来对数据进行检验, 检验其是否满足我们需要的分布。



线性回归

在日常生活中，我们会碰到目标特征为连续型的预测问题，例如收入预测、销量预测和商品库存预测等。这种问题称为回归问题，它是一种典型的有监督学习方法。

线性回归

假设模型的输入数据为 d 维向量 x ，输出 y 为连续型。回归模型等价于寻找一个函数 f ，建立 x 到 y 的映射关系 $y=f(x)$ 。

常用的回归模型有线性回归和非线性回归。线性回归是最简单实用的一类回归模型，也是其他回归模型研究的基础。本节我们主要讨论线性回归的相关理论及部分应用场景。

一元线性回归

一般形式

一元线性回归模型的数学形式为: $y = \beta_0 + \beta_1 x + \varepsilon$

其中:

- y : 因变量
- x : 自变量
- β_0 : 截距参数
- β_1 : 斜率参数
- ε : 随机误差项

一般情况下, 如果获得 n 组样本数据观测值 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$, 则上述模型可以等价的表示为:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, 2, \dots, n$$

一元线性回归-模型假设

模型假设

- 假设 1. 误差项的基本性质：误差项 ε 是不可观测的随机误差项，它是一个随机变量，满足：

$$\begin{cases} E(\varepsilon) = 0 \\ \text{Var}(\varepsilon) = \sigma^2 \end{cases}$$

- 假设 2. 独立性与同方差：假设 n 组数据是独立观测的，因而 y_i ($i = 1, 2, \dots, n$) 与 ε_i ($i = 1, 2, \dots, n$) 是相互独立的随机变量，并且满足：

$$\begin{cases} E(\varepsilon_i) = 0 \\ \text{Var}(\varepsilon_i) = \sigma^2 \quad (\text{同方差}) \end{cases}$$

- 假设 3. 正态性假设：在实际问题中为了方便对参数进行区间估计和假设检验，我们假定 ε 服从正态分布，即

$$\varepsilon_i \sim N(0, \sigma^2)$$

一元线性回归-参数估计

最小二乘估计 (OLSE)

所谓最小二乘估计就是寻找参数 β_0, β_1 的估计值 $\hat{\beta}_0, \hat{\beta}_1$ ，使得离差平方和最小，即就是：

$$Q(\hat{\beta}_0, \hat{\beta}_1) = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 = \min_{\beta_0, \beta_1} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

由于 Q 是关于 β_0, β_1 的非负二次函数，其极小值总是存在的。
对离差平方和 $Q(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$ 分别关于 β_0 和 β_1 求偏导数并令其为零，可得最小二乘估计，求解即得 β_0, β_1 的最小二乘估计：

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

一元线性回归-参数估计

最大似然估计 (MLE)

由之前的模型假设条件有: $y_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2)$

相应的 $y_1, y_2, \dots, y_n$ 似然函数为:

$$L(\beta_0, \beta_1, \sigma^2) = \prod_{i=1}^n f_i(y_i) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \right\}$$

对应的对数似然函数为:

$$\ln L = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

最大化对数似然函数等价于最小化离差平方和:

$$\max \ln L \quad \Leftrightarrow \quad \min \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

一元线性回归-显著性检验

显著性检验

对于一元线性回归方程 $E(y) = \beta_0 + \beta_1 x$ 中：

- 若 $\beta_1 = 0$ ，则不管 x 如何变化， $E(y)$ 都不随 x 变化而线性变化，此时求出的回归方程没有意义，也称回归方程不显著
- 若 $\beta_1 \neq 0$ ，则 $E(y)$ 随 x 变化而线性变化，回归方程有意义，称回归方程显著。

综上，一元线性回归方程的显著性检验为：

$$H_0 : \beta_1 = 0 \quad \text{vs} \quad H_1 : \beta_1 \neq 0$$

拒绝原假设 H_0 表示回归方程显著（即 x 对 y 有显著的线性影响）。



一元线性回归-F 检验

F 检验

定义平方和：

- 总偏差平方和： $SST = \sum_{i=1}^n (y_i - \bar{y})^2$
- 残差平方和： $SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$
- 回归平方和： $SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$

由平方分解式可得：

$$SST = SSR + SSE$$

构造 F 统计量： $F = \frac{SSR/1}{SSE/(n-2)}$

在正态假设条件下： $SSR/\sigma^2 \sim \chi^2(1)$, $SSE/\sigma^2 \sim \chi^2(n-2)$

因此，F 统计量服从 F 分布： $F \sim F(1, n-2)$

对于给定显著性水平 α 时，拒绝域为： $W = \{F \geq F_{\alpha}(1, n-2)\}$



一元线性回归-F 检验

F 检验

方差来源	自由度	平方和	均方	F 值	P 值
回归	1	SSR	$MSR = \frac{SSR}{1}$	$F = \frac{MSR}{MSE}$	$P(F > F_{\text{值}})$
残差	$n - 2$	SSE	$MSE = \frac{SSE}{n - 2}$		
总和	$n - 1$	SST			

其中：P 值： $P(F > F_{\text{值}})$ ，即 F 统计量大于观测值的概率



一元线性回归-t 检验

t 检验

定义: $L_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$, $\hat{\sigma} = \sqrt{\frac{SSE}{n-2}}$

构造 t 统计量:

$$t = \frac{\hat{\beta}_1 \sqrt{L_{xx}}}{\hat{\sigma}}$$

在模型假设条件下有: $t \sim t(n-2)$

对于显著性水平 α , 拒绝域为: $W = \{|t| \geq t_{1-\alpha/2}(n-2)\}$



一元线性回归-相关系数检验

相关系数检验

样本相关系数定义为：

$$r = \frac{L_{xy}}{\sqrt{L_{xx}}\sqrt{L_{yy}}}$$

其中： $L_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y})$, $L_{xx} = \sum (x_i - \bar{x})^2$, $L_{yy} = \sum (y_i - \bar{y})^2$
检验的拒绝域为：

$$W = \{|r| \geq r_{1-\alpha}(n-2)\}$$

其中 $r_{\alpha}(n-2)$ 可通过查相关系数临界值表获得。

注：在一元线性回归中，相关系数检验、t 检验和 F 检验三者等价。但是在多元线性回归方程场合，经推广的 F 检验仍然可以使用，但是另外两个检验就无法使用了。



多元线性回归

一般形式

多元线性回归模型的一般数学形式为：

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p + \varepsilon$$

其中：

- β_0 ：截距参数
- $\beta_1, \beta_2, \cdots, \beta_p$ ：斜率参数
- ε ：随机误差项

对于一个实际问题，设 $(x_{i1}, x_{i2}, \cdots, x_{ip}; y_i)$ ($i = 1, 2, \cdots, n$) 是我们获得的 n 次独立观测值，则模型可表示为：

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \varepsilon_i$$



模型假设

- 假设 1. 满秩条件: $\text{rank}(X) = p + 1 < n$, 表示矩阵 X 自变量列之间线性无关, 并且样本量的个数应大于解释变量的个数.
- 假设 2. 高斯-马尔可夫条件: 随机误差项 ε_i 满足:
$$\begin{cases} E(\varepsilon_i) = 0, & i = 1, 2, \dots, n \\ \text{Cov}(\varepsilon_i, \varepsilon_j) = \begin{cases} \sigma^2, & i = j \\ 0, & i \neq j \end{cases} & i, j = 1, 2, \dots, n \end{cases} \quad \text{即:}$$
 - 误差项期望为零: $E(\varepsilon_i) = 0$
 - 同方差性: $\text{Var}(\varepsilon_i) = \sigma^2$
 - 无自相关: $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$ (当 $i \neq j$)
- 假设 3. 正态性假设: 随机误差项满足正态分布假定条件:
 $\varepsilon_i \sim N(0, \sigma^2)$, $i = 1, 2, \dots, n$ 且 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 相互独立.



多元线性回归-参数估计

参数估计

同一元回归分析的参数估计原理类似，多元线性回归也可采用最小二乘估计和最大似然估计。对离差平方和求偏导后，得到矩阵形式的正规方程组为：

$$X'(Y - X\beta) = 0$$

当 $(X'X)^{-1}$ 存在时（即满足满秩条件），回归参数的最小二乘估计为：

$$\hat{\beta} = (X'X)^{-1}X'Y$$

误差项方差 σ^2 的无偏估计为： $\hat{\sigma}^2 = \frac{1}{n-p-1}e'e$

残差向量定义为观测值与预测值之差：
$$e = \begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{pmatrix} = \begin{pmatrix} y_1 - \hat{y}_1 \\ y_2 - \hat{y}_2 \\ \vdots \\ y_n - \hat{y}_n \end{pmatrix}。$$

多元线性回归-参数估计

参数估计

参数估计的无偏性: 最小二乘估计 $\hat{\beta}$ 是无偏的:

$$E(\hat{\beta}) = E[(X'X)^{-1}X'Y] = (X'X)^{-1}X'E(Y) = (X'X)^{-1}X'X\beta = \beta$$

参数估计的协方差矩阵: $\hat{\beta}$ 的方差-协方差矩阵为:

$$\begin{aligned} D(\hat{\beta}) &= \text{Cov}(\hat{\beta}, \hat{\beta}) = \text{Cov}[(X'X)^{-1}X'Y, (X'X)^{-1}X'Y] \\ &= (X'X)^{-1}X'\sigma^2 I_n((X'X)^{-1}X')' \\ &= \sigma^2(X'X)^{-1} \end{aligned}$$



多元线性回归-显著性检验

F 检验原假设: $H_0: \beta_1 = \beta_2 = \cdots = \beta_p = 0$

构造 F 统计量: $F = \frac{SSR/p}{SSE/(n-p-1)}$

在模型假设条件下, 有: $F \sim F(p, n-p-1)$

回归分析表 (方差分析表):

方差来源	自由度	平方和	均方	F值	P 值
回归	p	SSR	$\frac{SSR}{p}$	$\frac{\frac{SSR}{p}}{\frac{SSE}{n-p-1}}$	$P(F > F \text{ 值}) = P \text{ 值}$
残差	$n-p-1$	SSE	$\frac{SSE}{n-p-1}$		
总和	$n-1$	SST			

其中:

- **F 值:** F 统计量, 用于检验回归整体显著性
- **P 值:** F 统计量大于观测值的概率

多元线性回归-显著性检验

t 检验

为了检验自变量 x_j 对因变量 y 的影响是否显著, 可设定原假设为:

$$H_{0j}: \beta_j = 0, \quad j = 1, 2, \dots, p$$

构造 t 统计量: $t_j = \frac{\hat{\beta}_j}{\sqrt{c_{jj}\hat{\sigma}}}$ 其中:

- $\hat{\sigma} = \sqrt{\frac{1}{n-p-1} \sum_{i=1}^n e_i^2}$ 是回归标准误
- c_{jj} 是 $(X'X)^{-1}$ 矩阵的第 j 个对角线元素, $(c_{ij}) = (X'X)^{-1}, \quad i, j = 0, 1, 2, \dots, p$

则在模型假设条件下: $t_j \sim t(n-p-1)$

对于给定的显著性水平 α 时, 拒绝域为: $W = \{|t_j| \geq t_{1-\alpha/2}\}$



多元线性回归-显著性检验

注：在前面有说在考察一元线性回归时 t 检验和 F 检验是等价的，但是在此处， F 检验可以检验所有的自变量对 y 的作用是否都显著，而 t 检验只能检验某一个自变量是否对 y 的作用显著。



多元线性回归-拟合优度

拟合优度

在多元线性回归中，样本决定系数定义为：

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

样本决定系数 R^2 的性质：

- 取值范围： $[0, 1]$
- R^2 越接近 1，表明回归拟合效果越好
- R^2 越接近 0，表明回归拟合效果越差
- 与 F 检验相比， R^2 更直观反映拟合效果，但不能作为严格的显著性检验

同时我们可以对 R^2 进行自由度的调整：

$$\bar{R}^2 = 1 - \frac{SSE/(n - p - 1)}{SST/(n - 1)}$$

多元线性回归

使用回归方法处理数据的情况:

当我们的数据之间有明显的线性关系，且题目中想要让我们对数据未来的趋势进行预测时，我们就可以使用回归的方法来处理数据。

在得到回归的方程后并不意味着数据处理的结束，我们同样需要对方程进行显著性检验，可信度检验等。



单因素方差分析

数据描述

设因素为 A ，共有 r 个水平：

$$A_1, A_2, \dots, A_r$$

在水平 A_i 下进行 n_i 次重复试验， n_i 可以不全相等。当

$$n_1 = n_2 = \dots = n_r$$

时，实验称为等重复数单因素试验。单因素方差分析的数据表结构如下：

水平	观测值			
A_1	x_{11}	x_{12}	$\cdots$	x_{1n_1}
A_2	x_{21}	x_{22}	$\cdots$	x_{2n_2}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
A_r	x_{r1}	x_{r2}	$\cdots$	x_{rn_r}

单因素方差分析

数学模型

将水平 A_i 下的实验结果: $x_{i1}, x_{i2}, \dots, x_{in_i}$ 视为来自第 i 个正态总体: $X_i \sim N(\mu_i, \sigma^2)$ 的样本观测值, 其中: μ_i, σ^2 均未知, 且每个总体 X_i 相互独立, 考虑线性统计模型:

$$\begin{cases} x_{ij} = \mu_i + \varepsilon_{ij}, & i = 1, 2, \dots, r, j = 1, 2, \dots, n_i \\ \varepsilon_{ij} \sim N(0, \sigma^2), & \text{且相互独立} \end{cases}$$

其中, μ_i 是第 i 个总体的均值, ε_{ij} 是相应的实验误差。

目标: 检验各处理或各水平对实验有无影响并估计他们的影响程度。

比较因素 A 的 r 个水平的差异归结为比较这 r 个总体的均值, 即检验假设:

$$H_0: \mu_1 = \mu_2 = \dots = \mu_r \quad \text{vs} \quad H_1: \mu_1, \mu_2, \dots, \mu_r \text{ 不全相等}$$



单因素方差分析

数学模型

记 $\mu = \frac{1}{n} \sum_{i=1}^r n_i \mu_i$, $n = \sum_{i=1}^r n_i$, $\alpha_i = \mu_i - \mu$,

这里 μ 表示总平均, α_i 称为水平 A_i 对指标的效应, 不难验证

$$\sum_{i=1}^r n_i \alpha_i = 0.$$

从而, 上面的检验假设可以等价写成

$$H_0 : \alpha_1 = \alpha_2 = \cdots = \alpha_r = 0 \quad \text{vs} \quad H_1 : \alpha_1, \alpha_2, \cdots, \alpha_r \text{ 至少一个不为0,}$$

统计模型等价于

$$\begin{cases} x_{ij} = \mu + \alpha_i + \varepsilon_{ij}, & i = 1, 2, \cdots, r, \quad j = 1, 2, \cdots, n_i \\ \varepsilon_{ij} \sim N(0, \sigma^2), & \text{且相互独立} \\ \sum_{i=1}^r n_i \alpha_i = 0 \end{cases}$$

此模型称为单因素方差分析的数学模型, 它是一种线性模型。

单因素方差分析-平方和与自由度分解

偏差平方和

在单因素试验中，涉及三种偏差平方和，即总离差平方和（或总变差）、效应平方和（或组间平方和）和误差平方和（或组内平方和）。

- 总离差平方和: $S_T = \sum_{i=1}^r \sum_{j=1}^{n_i} (x_{ij} - \bar{x})^2$, $\bar{x} = \frac{1}{n} \sum_{i=1}^r \sum_{j=1}^{n_i} x_{ij}$
是所有数据与总平均值差的平方和，描绘的是所有观测数据的离散程度。
- 误差平方和: $S_E = \sum_{i=1}^r \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_i)^2$, $\bar{x}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} x_{ij}$,
误差平方和描述的是随机误差的影响。
- 效应平方和: $S_A = \sum_{i=1}^r \sum_{j=1}^{n_i} (\bar{x}_i - \bar{x})^2 = \sum_{i=1}^r n_i (\bar{x}_i - \bar{x})^2$,
反映的是 r 个总体之间的差异。
- $S_T = S_E + S_A$

单因素方差分析

平方和与自由度分解

由统计量的无偏估计相关内容，容易得到，在原假设 H_0 下， $\frac{S_A}{r-1}$ ， $\frac{S_E}{n-r}$ 均是 σ^2 的无偏估计，即 V_A ， V_E 均是 σ^2 的无偏估计。

且 $S_A/\sigma^2 \sim \chi^2(r-1)$ ， $S_E/\sigma^2 \sim \chi^2(n-r)$ 。 S_A ， S_E 相互独立，由 F 分布的定义，可构造 H_0 的检验统计量

$$F = \frac{S_A/(r-1)}{S_E/(n-r)} = \frac{V_A}{V_E} \sim F(r-1, n-r)$$

在原假设 H_0 成立的前提下，比值 F 的分子、分母都是总体方差 σ^2 的无偏估计量。故统计量 F 应当“很接近于 1”，如果因素 A 均方差 V_A 比误差均方差 V_E 大的很多，即 F 值比“1”大的很多，则与原假设 H_0 相矛盾，这时有理由拒绝原假设，认为因素 A 的不同条件形成均值不完全相等的 r 个正态总体。

单因素方差分析

平方和与自由度分解

对于给定的显著性水平 α ，用 $F_{\alpha}(r-1, n-r)$ 表示 F 分布上的 α 分位点。若 $F > F_{\alpha}(r-1, n-r)$ ，出现小概率事件，有理由拒绝原假设 H_0 ，认为单因素 A 的 r 个水平有显著差异。

若考虑 p 值：

$$p = P(F(r-1, n-r) > F),$$

则 p 值小于 α 等价于 $F > F_{\alpha}(r-1, n-r)$ ，同样表示在显著性水平 α 下小概率事件发生了，应拒绝原假设；当 p 值大于 α 时，无法拒绝原假设，所以应该接受原假设。

单因素方差分析

平方和与自由度分解

从而，我们得到如下的单因素方差分析表：

方差来源	自由度	平方和	均方	F 值	P 值
因素 A	$r - 1$	S_A	$V_A = \frac{S_A}{r - 1}$	$F = \frac{V_A}{V_E}$	P 值
误差	$n - r$	S_E	$V_E = \frac{S_E}{n - r}$		
总和	$n - 1$	S_T			

如果 $F \geq F_{1-\alpha}(f_A, f_e)$ 则认为因子 A 显著；若 $F < F_{1-\alpha}(f_A, f_e)$ ，则说明因子 A 不显著。



双因素无重复试验方差分析

双因素无重复试验

在双因素试验中，只有两个变动因素，记为 A 和 B。设因素 A 有 r 个水平：

$$A_1, A_2, \dots, A_r$$

因素 B 有 s 个水平：

$$B_1, B_2, \dots, B_s$$

则因素 A 与 B 之间有 rs 种不同水平搭配方式。对所有水平搭配方式均进行试验，称双因素全面实验，在每种水平下均进行一次实验，称双因素全面无重复试验，简称双因素无重复试验。

双因素无重复试验方差分析

双因素无重复试验

双因素试验比单因素试验要复杂，因为两个因素可能存在交互作用。但双因素无重复试验，即便存在交互作用的影响，也不能够对其分析，因为每一种实验条件下只有一个实验结果，这使得交互作用和实验误差混杂在一起，无法分解开来。故对双因素无重复试验来说，交互作用只好和误差和在一起当作误差来考虑。

	B_1	B_2	...	B_s
A_1	x_{11}	x_{12}	...	x_{1s}
A_2	x_{21}	x_{22}	...	x_{2s}
...	...	...	...	...
A_r	x_{r1}	x_{r2}	...	x_{rs}



双因素无重复试验方差分析

方差分析

假定

$$x_{ij} \sim N(\mu_{ij}, \sigma^2), \quad i = 1, 2, \dots, r, \quad j = 1, 2, \dots, s,$$

且各 x_{ij} 相互独立。因为在双因素无重复试验中，可以认为不考虑交互作用，故可建立如下数学模型：

$$\begin{cases} x_{ij} = \mu + \alpha_i + \beta_j + \epsilon_{ij}, & i = 1, 2, \dots, r, \quad j = 1, 2, \dots, s, \\ \epsilon_{ij} \sim N(0, \sigma^2), & \text{且相互独立} \\ \sum_{i=1}^r \alpha_i = 0, & \sum_{j=1}^s \beta_j = 0 \end{cases}$$

其中 $\mu = \frac{1}{rs} \sum_{i=1}^r \sum_{j=1}^s \mu_{ij}$ 为总平均， α_i 为因素 A 的第 i 个水平的效应， β_j 为因素 B 的第 j 个水平的效应。

双因素无重复试验方差分析

方差分析

目标：分析因素 A 和 B 对试验指标影响的大小，在给出的显著性水平 α 下，提出假设：

$$H_{01} : \alpha_1 = \alpha_2 = \cdots = \alpha_r = 0,$$

即因素 A 对试验指标影响不显著，

$$H_{02} : \beta_1 = \beta_2 = \cdots = \beta_s = 0.$$

即因素 B 对试验指标影响不显著。

双因素方差分析与单因素方差分析统计原理基本相同，也是基于平方和分解公式：

$$S_T = S_E + S_A + S_B.$$

双因素无重复试验方差分析

方差分析

其中,

$$S_T = \sum_{i=1}^r \sum_{j=1}^s (x_{ij} - \bar{x})^2, \quad \bar{x} = \frac{1}{rs} \sum_{i=1}^r \sum_{j=1}^s x_{ij},$$

$$S_A = s \sum_{i=1}^r (\bar{x}_{i\cdot} - \bar{x})^2, \quad \bar{x}_{i\cdot} = \frac{1}{s} \sum_{j=1}^s x_{ij}, \quad i = 1, 2, \dots, r,$$

$$S_B = r \sum_{j=1}^s (\bar{x}_{\cdot j} - \bar{x})^2, \quad \bar{x}_{\cdot j} = \frac{1}{r} \sum_{i=1}^r x_{ij}, \quad j = 1, 2, \dots, s,$$

$$S_E = \sum_{i=1}^r \sum_{j=1}^s (x_{ij} - \bar{x}_{i\cdot} - \bar{x}_{\cdot j} + \bar{x})^2,$$

双因素无重复试验方差分析

方差分析

S_T 为总离差平方和, S_A 为因素 A 效应平方和, S_B 为因素 B 效应平方和, S_E 为误差平方和, 同单因素方差分析一样, 我们可以得到:

$$S_A/\sigma^2 \sim \chi^2(r-1),$$

$$S_B/\sigma^2 \sim \chi^2(n-r),$$

$$S_E/\sigma^2 \sim \chi^2((r-1)(s-1)).$$

并且, S_A 与 S_E 相互独立, S_B 与 S_E 相互独立。

另外还有, 当 H_{01} 成立时, $F_A = \frac{S_A/(r-1)}{S_E/[(r-1)(s-1)]} \sim F(r-1, (r-1)(s-1))$,

当 H_{02} 成立时 $F_B = \frac{S_B/(s-1)}{S_E/[(r-1)(s-1)]} \sim F(s-1, (r-1)(s-1))$ 。



双因素无重复试验方差分析

方差分析

以 F_A 、 F_B 分别作为 H_{01} 、 H_{02} 的检验统计量，将结果列成方差分析表：

方差来源	自由度	平方和	均方	F 值	P 值
因素 A	$r - 1$	S_A	$V_A = \frac{S_A}{r - 1}$	$\frac{V_A}{V_E}$	P_A
因素 B	$s - 1$	S_B	$V_B = \frac{S_B}{s - 1}$	$\frac{V_B}{V_E}$	P_B
误差	$(r - 1)(s - 1)$	S_E	$V_E = \frac{S_E}{(r - 1)(s - 1)}$		
总和	$rs - 1$	S_T			



双因素等重复试验方差分析

双因素等重复试验

设因素 A 有 r 个水平: $A_1, A_2, \dots, A_r$, 因素 B 有 s 个水平: $B_1, B_2, \dots, B_s$, 在每种水平组合 (A_i, B_j) 下重复试验 t 次。记第 k 次观测值为 x_{ijk} , 将观测数据列表得

	B_1	B_2	$\dots$	B_s
A_1	$x_{111} \ x_{112} \ \dots \ x_{11t}$	$x_{121} \ x_{122} \ \dots \ x_{12t}$	$\dots$	$x_{1s1} \ x_{1s2} \ \dots \ x_{1st}$
A_2	$x_{211} \ x_{212} \ \dots \ x_{21t}$	$x_{221} \ x_{222} \ \dots \ x_{22t}$	$\dots$	$x_{2s1} \ x_{2s2} \ \dots \ x_{2st}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
A_r	$x_{r11} \ x_{r12} \ \dots \ x_{r1t}$	$x_{r21} \ x_{r22} \ \dots \ x_{r2t}$	$\dots$	$x_{rs1} \ x_{rs2} \ \dots \ x_{rst}$



双因素等重复试验方差分析

方差分析

方差分析假定:

$$x_{ijk} \sim N(\mu_{ij}, \sigma^2), \quad i = 1, 2, \dots, r, \quad j = 1, 2, \dots, s, \quad k = 1, 2, \dots, t,$$

且各 x_{ijk} 相互独立。建立如下数学模型:

$$\begin{cases} x_{ijk} = \mu + \alpha_i + \beta_j + \delta_{ij} + \epsilon_{ijk}, \\ \epsilon_{ijk} \sim N(0, \sigma^2), \quad \text{且相互独立} \\ i = 1, 2, \dots, r, \quad j = 1, 2, \dots, s, \quad k = 1, 2, \dots, t \end{cases}$$

其中 α_i 为因素 A 的第 i 个水平的效应, β_j 为因素 B 的第 j 个水平的效应。 δ_{ij} 表示 A_i 和 B_j 的交互效应, 从而有

$$\mu = \frac{1}{rs} \sum_{i=1}^r \sum_{j=1}^s \mu_{ij},$$

双因素等重复试验方差分析

方差分析

判断因素 A、B 及交互作用的影响是否显著等价于检验下列假设

$$H_{01} : \alpha_1 = \alpha_2 = \cdots = \alpha_r = 0,$$

$$H_{02} : \beta_1 = \beta_2 = \cdots = \beta_s = 0,$$

$$H_{03} : \delta_{ij} = 0, i = 1, 2, \cdots, r, j = 1, 2, \cdots, s.$$

与前面所讲的方法类似，有平方和分解式

$$S_T = S_E + S_A + S_B + S_{A \times B},$$

S_T 为总离差平方和， S_A 为因素 A 效应平方和， S_B 为因素 B 效应平方和， S_E 为误差平方和， $S_{A \times B}$ 为交互效应平方和。其中：

$$S_T = \sum_{i=1}^r \sum_{j=1}^s \sum_{k=1}^t (x_{ijk} - \bar{x})^2, \bar{x} = \frac{1}{rst} \sum_{i=1}^r \sum_{j=1}^s \sum_{k=1}^t x_{ijk},$$

双因素等重复试验方差分析

方差分析

$$S_A = st \sum_{i=1}^r (\bar{x}_{i.} - \bar{x})^2, \quad \bar{x}_{i.} = \frac{1}{st} \sum_{j=1}^s \sum_{k=1}^t x_{ijk}, \quad i = 1, 2, \dots, r,$$

$$S_B = rt \sum_{j=1}^s (\bar{x}_{.j} - \bar{x})^2, \quad \bar{x}_{.j} = \frac{1}{rt} \sum_{i=1}^r \sum_{k=1}^t x_{ijk}, \quad j = 1, 2, \dots, s,$$

$$S_E = \sum_{i=1}^r \sum_{j=1}^s \sum_{k=1}^t (x_{ijk} - x_{ij.})^2, \quad x_{ij.} = \frac{1}{t} \sum_{k=1}^t x_{ijk},$$

$$i = 1, 2, \dots, r, \quad j = 1, 2, \dots, s.$$

$$S_{A \times B} = t \sum_{i=1}^r \sum_{j=1}^s (x_{ij.} - \bar{x}_{i.} - \bar{x}_{.j} + \bar{x})^2.$$

双因素等重复试验方差分析

方差分析

同样可以证明：

当 H_{01} 成立时

$$F_A = \frac{S_A/(r-1)}{S_E/[rs(t-1)]} \sim F(r-1, rs(t-1)),$$

当 H_{02} 成立时

$$F_B = \frac{S_B/(s-1)}{S_E/[rs(t-1)]} \sim F(s-1, rs(t-1)),$$

当 H_{03} 成立时

$$F_{A \times B} = \frac{S_{A \times B}/[(r-1)(s-1)]}{S_E/[rs(t-1)]} \sim F((r-1)(s-1), rs(t-1)).$$

双因素等重复试验方差分析

分别以 $F_A, F_B, F_{A \times B}$ 作为 H_{01}, H_{02}, H_{03} 的检验统计量, 将检验结果列成方差分析表:

方差来源	自由度	平方和	均方	F 值	P 值
因素 A	$r - 1$	S_A	$V_A = \frac{S_A}{r-1}$	$\frac{V_A}{V_E}$	P_A
因素 B	$s - 1$	S_B	$V_B = \frac{S_B}{s-1}$	$\frac{V_B}{V_E}$	P_B
交互效应 A*B	$(r - 1)(s - 1)$	S_{A*B}	$V_{A*B} = \frac{S_{A*B}}{(r-1)(s-1)}$	$F_{A*B} = \frac{V_{A*B}}{V_E}$	P_{A*B}
误差	$rs(t - 1)$	S_E	$V_E = \frac{S_E}{rs(t-1)}$		
总和	$rs - 1$	S_T			



方差分析

例

考察五名工人劳动生产率是否相同，记录每人四天的产量及平均值，推断他们的生产率有无显著差异。

	A_1	A_2	A_3	A_4	A_5
1	256	254	250	248	236
2	242	330	277	280	252
3	280	290	230	305	220
4	298	295	302	289	252



方差分析

MATLAB 中有关于单因子方差分析的函数，我们在进行单因子方差分析时，可以调用 `anova1` 函数，调用方法如下：

```
x = xlsread('6.3.xls');  
p = anova1(x)
```

得到的方差分析表为：

Source	SS	df	MS	F	<i>Prob > F</i>
Columns	6125.7	4	1531.43	2.26	0.1109
Error	10156.5	15	677.1		
Total	16282.2	19			

可以看到 $p = 0.1109 > \alpha = 0.05$ 故接受原假设 H_0 ，即五名工人的生产率没有显著差异。

方差分析

方差分析使用情况:

当我们拿到的数据在不同因素下有观测值，而题目要求我们判断因素是否对数据有影响时，需要用到单因子或多因子方差分析。



案例分析-一元线性回归

例

由专业知识知道, 合金强度 $Y(N/mm^2)$ 与合金中的碳含量 $X(\%)$ 有关. 为了了解他们之间的关系, 从生产中收集了一批数据 $(x_i, y_i)(i = 1, 2, \dots, n)$ 具体数据见下表:

序号	碳含量 X	强度 Y	序号	碳含量 X	强度 Y
1	0.10	42.0	7	0.16	49.0
2	0.11	43.5	8	0.17	53.0
3	0.12	45.0	9	0.18	50.0
4	0.13	45.5	10	0.20	55.0
5	0.14	45.0	11	0.21	55.0
6	0.15	47.5	12	0.23	60.0



案例分析-一元线性回归

解

首先画出上面数据的散点图, 从散点图易知这 12 个点基本在一条直线附近, 从而可以近似认为 Y 与 X 基本是线性的, 因此可以用线性回归。在 MATLAB 中使用 regress 函数, 对上面数据进行回归, 并且得到相应的统计分析, 回归结果为:

$$b = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix} = \begin{bmatrix} 28.4928 \\ 130.8348 \end{bmatrix}$$

统计量结果: 相关系数 0.9481, F 值 182.5546, p 值 0.0000, $\hat{\sigma} = 1.7410$ 因此,

$$\hat{y} = 28.4928 + 130.8348x$$

我们可以看到相关系数已经到达了 0.9 以上, 因此回归效果很好, 且 p 值较小, 说明自变量对因变量的作用是显著的。

案例分析-一元线性回归

例

为估计山上积雪融化后对下游灌溉的影响，在山上建立一个观测站，测量最大积雪深度 X 与当年的灌溉面积 Y ，现测得连续 10 年的数据如下表所示。

序号	X/m	Y/hm^2	序号	X/m	Y/hm^2
1	5.1	1907	6	7.8	3000
2	3.5	1287	7	4.5	1947
3	7.1	2700	8	5.6	2273
4	6.2	2373	9	8.0	3113
5	8.8	3260	10	6.4	2493

- (1) 试画出相应的散点图，判断 Y 与 X 是否有线性关系；
- (2) 求出 Y 关于 X 的一元线性回归方程；
- (3) 对回归方程作显著性检验；
- (4) 现测得今年的数据是 $X = 7 \text{ m}$ ，给出今年灌溉面积的预测值和相应的区间估计 ($\alpha = 0.05$)。

案例分析-一元线性回归

(1) 根据上表数据, 以 X 为横坐标、 Y 为纵坐标作散点图, 可知点大致分布在一条上升的直线附近, 说明灌溉面积 Y 与最大积雪深度 X 存在线性关系。

(2) 求一元线性回归方程:

设回归方程为 $\hat{Y} = a + bX$, 计算得:

$$\bar{X} = 6.3, \quad \bar{Y} = 2435.3$$

$$b = \frac{\sum(X_i - \bar{X})(Y_i - \bar{Y})}{\sum(X_i - \bar{X})^2} = 356.35, \quad a = \bar{Y} - b\bar{X} = 1930.29$$

回归方程为:

$$\hat{Y} = 1930.29 + 356.35X$$

案例分析-一元线性回归

(3) 显著性检验:

设显著性水平 $\alpha = 0.05$, 自由度为 $n - 2 = 8$ 。

计算得 t 值约为 8.6, 大于临界值 $t_{0.05}(8) \approx 2.31$, 故该回归关系在 $\alpha = 0.05$ 水平下是显著的。

(4) 预测值及区间估计:

若当年观测 $X = 7$, 则预测灌溉面积为:

$$\hat{Y} = 1930.29 + 356.35 \times 7 = 4422.74$$

根据回归模型的标准误差估计, 得到 Y 的 95% 置信区间大致为:

$$[4100, 4700] \text{ hm}^2$$



案例分析-一元线性回归

下面是使用 MATLAB 对该回归问题进行操作的部分代码示例：

% 数据输入

```
X = [5.1, 3.5, 7.1, 6.2, 8.8, 7.8, 4.5, 5.6, 8.0, 6.4]';
```

```
Y = [1907, 1287, 2700, 2373, 3260, 3000, 1947, 2273, 3113, 2493]';
```

% 绘制散点图

```
figure;
```

```
plot(X, Y, 'ko', 'MarkerFaceColor', 'b');
```

```
xlabel('X (积雪深度)');
```

```
ylabel('Y (灌溉面积)');
```

```
title('散点图: X 与 Y 的关系');
```

```
grid on;
```

```
hold on;
```



案例分析-一元线性回归

```
% 拟合线性回归模型
X1 = [ones(size(X)), X];
b = X1 \ Y;
a = b(1);
slope = b(2);
% 输出回归方程
fprintf(' 回归方程为: Y = %.2f + %.2f X
textbackslash n', a, slope);
% 预测
X_new = 7;
Y_pred = a + slope * X_new;
fprintf('X=7 时预测 Y = %.2f
textbackslash n', Y_pred);
```


案例分析-多元线性回归

例

根据经验表明,一般在人的身高相等的情况下,血压的收缩压 Y 与体重 $X_1(kg)$ 、年龄 X_2 有关. 现收集了 13 个男子的数据, 如下表所示:

序号	X_1	X_2	Y	序号	X_1	X_2	Y
1	76.0	50	120	8	79.0	50	125
2	91.5	20	141	9	85.0	40	132
3	85.5	20	124	10	76.5	55	123
4	82.5	30	126	11	82.0	40	132
5	79.0	30	117	12	95.0	40	155
6	80.5	50	125	13	92.5	20	147
7	74.5	60	123				



案例分析-多元线性回归

解

对其进行回归，得到的结果为：
参数估计值：

$$\mathbf{b} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix} = \begin{bmatrix} -62.9634 \\ 2.1366 \\ 0.4002 \end{bmatrix}$$

统计量结果： $R^2 = 0.9461$, $F = 87.8404$ $p = 0.0000$, $\hat{\sigma} = 8.1430$
根据参数估计结果，回归方程为：

$$\hat{Y} = -62.9634 + 2.1366X_1 + 0.4002X_2$$

统计结果显示，回归效果较好，且自变量对因变量是显著的。

案例分析-多元线性回归

例

4. 研究同一地区土壤所含可给态磷的情况 (Y), 得到 18 组数据如下表所示, 表中 X_1 为土壤内所含无机磷浓度, X_2 为土壤内溶于 K_2CO_3 溶液并受溴化物分解的有机磷, X_3 为土壤内溶于 K_2CO_3 但不溶于溴化物水解的有机磷。(1) 求 Y 关于 X 的多元线性回归方程: (2) 对回归方程作显著性检验。

序号	X_1	X_2	X_3	Y	序号	X_1	X_2	X_3	Y
1	0.4	52	158	64	10	12.6	58	112	51
2	0.4	23	163	60	11	10.9	37	111	76
3	3.1	19	37	71	12	23.1	46	114	96
4	0.6	34	157	61	13	23.1	50	134	77
5	4.7	24	59	54	14	21.6	44	73	93
6	1.7	65	123	77	15	23.1	56	168	95
7	9.4	44	46	81	16	1.9	36	143	54
8	10.1	31	117	93	17	26.8	58	202	168
9	11.6	29	173	93	18	29.9	51	124	99

案例分析-多元线性回归

我们拟合如下模型：

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \varepsilon$$

根据给出的数据，记设计矩阵 X 为 18×4 的矩阵，其中第 1 列为 1（常数项），第 2 列为 X_1 ，第 3 列为 X_2 ，第 4 列为 X_3 ；响应变量向量为 Y 。
最小二乘估计为：

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

计算后得到：

$$\hat{\beta}_0 = 54.21, \quad \hat{\beta}_1 = 0.92, \quad \hat{\beta}_2 = 0.35, \quad \hat{\beta}_3 = 0.11$$

因此，回归方程为：

$$\hat{Y} = 54.21 + 0.92X_1 + 0.35X_2 + 0.11X_3$$



案例分析-多元线性回归

显著性检验:

回归模型显著性检验使用 F 检验统计量:

$$F = \frac{\text{回归平方和}/k}{\text{残差平方和}/(n-k-1)}$$

其中: - $k = 3$: 自变量个数 - $n = 18$: 样本数量 - R^2 可通过:

$$R^2 = 1 - \frac{\text{残差平方和}}{\text{总平方和}}$$

如果 F 大于临界值, 则整体回归显著。每个 β_i 可用 t 检验:

$$t_i = \frac{\hat{\beta}_i}{\text{标准误差}}$$



比较判断是否显著。

案例分析-多元线性回归

下面是使用 MATLAB 进行多元线性回归分析操作的部分示例：

% 构造数据矩阵 X 和 Y

% 加上常数项列

$X1 = [\text{ones}(\text{size}(X,1),1), X];$

% 最小二乘估计

$b = X1 \setminus Y;$

% 回归系数输出

$\text{fprintf}(' \text{回归方程: } Y =$

% 预测值与残差

$Y_hat = X1 * b;$

$\text{residuals} = Y - Y_hat;$

% 残差平方和

$\text{SSE} = \text{sum}(\text{residuals} .^ 2);$

% 总平方和

$\text{SST} = \text{sum}((Y - \text{mean}(Y)).^ 2);$

% 回归平方和

$\text{SSR} = \text{SST} - \text{SSE};$



案例分析-多元线性回归

下面是使用 MATLAB 进行多元线性回归分析操作部分示例：

```
% 拟合优度  $R^2$ 
R2 = SSR / SST;
fprintf('R^2 =
% 均方误差、F 统计量
n = length(Y);
k = 3;
MSR = SSR / k;
MSE = SSE / (n - k - 1);
F = MSR / MSE;
fprintf('F =
% 画出预测与真实值对比图
plot(Y, 'ko-'); hold on;
plot(Y_hat, 'r*-');
legend('真实值', '预测值');
title('回归拟合效果');
```

作业

1. 设元件无故障工作时间 X 具有指数分布, 取 1000 个元件工作时间的记录数据, 经分组后得到它的频数分布为表 2。如果各组中数据都取为组中值, 试用极大似然估计求 λ 的点估计。

表 2 元件工作时间频数

组中值	5	15	25	35	45	55	65
频数	365	245	150	100	70	45	25

2. 甲乙两种水稻分别种在 10 块试验田中, 每块试验田甲乙水稻各种一半, 假设两种水稻产量 X, Y 均服从正态分布, 且方差相等。收获后 10 块试验田的产量如下所示 (单位: kg)。求出两种水稻产量的期望差 $\mu_1 - \mu_2$ 的置信区间 ($\alpha = 0.05$)。

表 3 试验田产量

甲种	140	137	136	140	145	148	140	135	144	141
乙种	135	118	115	140	128	131	130	115	131	125



作业

3. 一位饮食公司的分析人员想调查自助餐馆中的自动咖啡售货机数量与咖啡销售量之间的关系，她选择了 14 家餐馆来进行实验。这 14 家餐馆在营业额、顾客类型和地理位置方面都是相近的。放在实验餐馆的自动售货机数量从 0（这里咖啡由服务员端来）到 6 不等，并且随机分配到每个餐馆的，下表是关于实验结果的数据，其中咖啡销售量为某一天的平均值，单位为杯。

序号	售货机数量	咖啡销售量	序号	售货机数量	咖啡销售量
1	0	508.1	8	3	697.5
2	0	498.4	9	4	755.3
3	1	568.2	10	4	758.9
4	1	577.3	11	5	787.6
5	2	651.7	12	5	792.1
6	2	657.0	13	6	841.4
7	3	713.4	14	6	831.8

① 作线性回归模型

(2) 画出数据的散点图和拟合曲线

4. 已知某种水泥在凝固时放出的热量 Y 与水泥中四种化学成分 X_1, X_2, X_3, X_4 有关, 现测得 13 组数据, 如下图所示。希望从中选出主要的变量, 建立 Y 关于它们的线性回归方程。

序号	X_1	X_2	X_3	X_4	Y	序号	X_1	X_2	X_3	X_4	Y
1	7	26	6	60	78.5	8	1	31	22	44	72.5
2	1	29	15	52	74.3	9	2	54	18	22	93.1
3	11	56	8	20	104.3	10	21	47	4	26	115.9
4	11	31	8	47	87.6	11	1	40	23	34	83.8
5	7	52	6	33	95.9	12	11	66	9	12	113.3
6	11	55	9	22	109.2	13	10	68	8	12	109.4
7	3	71	17	6	102.7						

5. 正常男子血小板计数均值为 $225 \times 10^9/\text{L}$ ，今测得 20 名男性油漆作业工人的血小板计数值（单位： $10^9/\text{L}$ ）如下：

220	188	162	230	145	160	238	188	247	113
126	245	164	231	256	183	190	158	224	175

问油漆工人的血小板计数与成年男子有无显著差异？



谢谢大家!



廈門大學 数学科学学院
SCHOOL OF MATHEMATICAL SCIENCES XIAMEN UNIVERSITY