

逻辑规则建模

AI 建模

厦门大学数学科学学院

2026 年 7 月 30 日

课程内容安排

- ① 问题起源：为什么 AI 建模需要逻辑规则
- ② 相关概念：命题、谓词、规则、推理与知识库
- ③ 核心要领：如何把现实知识转化为逻辑规则
- ④ 典型案例：分类、诊断、推荐、风控、排课与路径决策
- ⑤ 总结：逻辑规则建模的优势、局限与应用方法

一、问题起源：AI 建模为什么需要规则

AI 建模并不只是训练复杂模型。

在很多实际问题中，我们还需要把人类经验、业务约束和领域知识表达出来。

例如：

- 医学诊断中有明确的判断标准
- 金融风控中有合规规则
- 教务排课中有硬性约束
- 推荐系统中有禁推规则
- 智能客服中有业务流程规则



数据驱动模型的不足

单纯依赖数据训练模型，可能面临以下问题：

- 数据不足时，模型效果不稳定
- 数据有偏时，模型可能学习到错误模式
- 结果难以解释
- 无法保证满足硬性约束
- 对罕见但重要的情况处理不足

因此，AI 建模中常常需要引入逻辑规则。



逻辑规则的基本作用

逻辑规则可以帮助模型表达：

- 什么条件下应当采取某种判断
- 哪些情况必须排除
- 哪些约束不能违反
- 哪些结论可以由已知事实推出

简单地说，逻辑规则用于表达“如果……那么……”的知识。



从经验判断到数学表达

现实中常见的经验判断可以写成逻辑规则。

例如：

如果学生缺课次数超过三分之一，则该课程不能参加期末考试。
可表达为：

$$\text{缺课次数} > \text{总课时}/3 \Rightarrow \text{不能考试}$$

这就是从自然语言规则到数学逻辑表达的过程。

AI 建模中的两类知识

AI 建模通常同时利用两类知识：

- 数据知识：从样本中学习得到的统计规律
- 规则知识：由专家经验、制度约束或业务逻辑给出

数据知识回答“历史上通常怎样”。

规则知识回答“在什么条件下必须怎样”。

逻辑规则建模适合的问题

逻辑规则建模适合以下场景：

- 决策边界比较清楚
- 规则具有明确解释
- 约束条件不能违反
- 需要可追溯推理过程
- 数据量较少但专家知识较丰富

它常见于风控、诊断、排班、推荐过滤、智能问答等问题。



二、基本概念：事实

事实是系统中已经知道的信息。

例如：

- 学生 A 已修高等数学
- 学生 A 绩点为 3.8
- 订单金额为 12000 元

在逻辑规则建模中，事实是推理的起点。
没有事实，规则就无法产生具体结论。



基本概念：命题

命题是能够判断真假的陈述。

例如：

- P: 学生 A 通过了考试
- Q: 订单金额超过 10000 元

命题只能有两种状态：真或假。

逻辑规则常常建立在命题之间的关系上。



基本概念：逻辑联结词



常用逻辑联结词包括：

- 非： $\neg P$
- 且： $P \wedge Q$
- 或： $P \vee Q$
- 蕴含： $P \Rightarrow Q$
- 等价： $P \Leftrightarrow Q$

这些符号用于把简单命题组合成复杂规则。



且规则

且规则表示多个条件必须同时成立。

例如：

成绩 $\geq 60 \wedge$ 出勤合格 $\Rightarrow$ 课程通过

它的含义是：

只有成绩达标并且出勤合格，才能判断课程通过。

在 AI 决策中，且规则常用于硬条件筛选。



或规则

或规则表示多个条件中至少一个成立。

例如：

高风险地区旅居史 $\vee$ 密切接触史 $\Rightarrow$ 需要重点筛查

它的含义是：

只要满足其中一个条件，就触发相应结论。

或规则常用于风险预警、异常检测和快速筛查。

非规则

非规则用于表示排除条件。

例如：

¬ 已完成实名认证 $\Rightarrow$ 不能进行交易

其含义是：

如果用户没有完成实名认证，则不能进入后续操作。

非规则在合规、权限控制和流程管理中非常常见。

蕴含规则

蕴含规则是逻辑规则建模中最常见的形式。

一般写作：

$$P \Rightarrow Q$$

含义是：

如果条件 P 成立，那么结论 Q 成立。

例如：

$$\text{年龄} < 18 \Rightarrow \text{未成年人}$$



谓词与对象

命题逻辑只能表示整体真假。
谓词逻辑可以描述对象及其属性。
例如：

$$Student(x)$$

表示 x 是学生。

$$Passed(x, Course)$$

表示 x 通过了某门课程。
谓词逻辑更适合表达复杂现实问题。



变量与量词



谓词逻辑中常用量词包括：

- 全称量词： $\forall x$ ，表示对所有 x 成立
- 存在量词： $\exists x$ ，表示存在某个 x 成立

例如：

$$\forall x, Student(x) \Rightarrow Person(x)$$

表示所有学生都是人。



规则的一般形式

逻辑规则通常写成：

条件₁ $\wedge$ 条件₂ $\wedge \cdots \wedge$ 条件_n $\Rightarrow$ 结论

例如：

发热 $\wedge$ 咳嗽 $\wedge$ 接触史 $\Rightarrow$ 疑似感染

其中左边是前提，右边是结论。

知识库

知识库是事实和规则的集合。

可以写作：

知识库 = 事实集合 + 规则集合

例如：

事实：

学生 A 修过高等数学

规则：

修过高等数学 $\Rightarrow$ 可以修数学建模

于是可以推出：

学生 A 可以修数学建模



推理

推理是根据已有事实和规则得到新结论的过程。
基本形式为：

事实 + 规则 $\Rightarrow$ 结论

例如：

$P, \quad P \Rightarrow Q$

则可推出：

Q

这就是最基本的演绎推理。



正向推理

正向推理从已有事实出发，不断应用规则推出新事实。
基本过程是：

已知事实 $\rightarrow$ 匹配规则 $\rightarrow$ 生成结论

例如：

已知某用户年龄小于 18 岁。

规则为：

年龄 $< 18 \Rightarrow$ 未成年人

则推出该用户为未成年人。

反向推理

反向推理从目标结论出发，反向寻找需要满足的条件。
基本过程是：

目标结论 $\rightarrow$ 所需条件 $\rightarrow$ 验证事实

例如，要判断学生是否可以毕业，需要检查：

- 学分是否达到要求
- 必修课是否通过
- 论文是否合格
- 处分记录是否满足规定

确定性规则与不确定性规则

确定性规则是指条件满足时结论必然成立。

例如：

年龄 $< 18 \Rightarrow$ 未成年人

不确定性规则是指条件满足时结论具有一定概率或置信度。

例如：

发热 $\wedge$ 咳嗽 $\Rightarrow$ 可能感染

AI 建模中经常需要处理不确定性规则。

规则权重

在不确定场景中，可以给规则赋予权重。
例如：

发热 $\Rightarrow$ 感染， 权重 = 0.4

发热 $\wedge$ 咳嗽 $\Rightarrow$ 感染， 权重 = 0.7

发热 $\wedge$ 咳嗽 $\wedge$ 接触史 $\Rightarrow$ 感染， 权重 = 0.9

权重表示规则结论的可信程度。

规则冲突

规则冲突是指不同规则推出相互矛盾的结论。
例如：

高信用评分 $\Rightarrow$ 低风险

近期多次逾期 $\Rightarrow$ 高风险

同一个用户可能同时满足两个条件。
因此需要设置优先级、权重或冲突解决机制。



规则优先级

当规则发生冲突时，可以按照优先级处理。
例如：

严重违规 $\Rightarrow$ 拒绝通过

即使其他条件良好，只要触发严重违规规则，就直接拒绝。
这类规则常称为强规则或硬规则。
硬规则通常优先于普通评分规则。

三、核心要领：明确建模对象

逻辑规则建模的第一步是明确对象。

例如：

- 学生
- 用户
- 商品
- 订单
- 病人
- 课程

只有明确对象，才能进一步定义属性和规则。



定义属性

对象通常具有多个属性。
例如用户对象可以具有：

- 年龄
- 注册时间
- 消费金额
- 信用等级
- 是否实名认证
- 是否存在异常行为

属性是规则判断的基础。



定义条件

条件是对属性的判断。

例如：

年龄 < 18

消费金额 > 10000

连续登录天数 ≥ 7

是否实名认证 = 否

条件要尽量清楚、可计算、可验证。



定义结论

结论是规则触发后得到的判断或动作。

例如：

- 判断为高风险
- 推荐某类课程
- 拒绝交易
- 进入人工审核
- 标记为重点关注对象

逻辑规则必须明确输出结果，否则难以用于建模。



规则建模的基本结构

一个完整规则通常包括：

- 对象：规则作用于谁
- 条件：满足什么情况
- 结论：推出什么结果
- 优先级：冲突时如何处理
- 解释：为什么这样判断

可写为：

对象 + 条件 $\Rightarrow$ 结论



规则提取

规则可以来自多个来源：

- 法律法规
- 业务制度
- 专家经验
- 历史数据
- 决策树或规则学习模型

实际建模中，人工规则和数据学习规则常常结合使用。



规则表达要清晰

一条规则要尽量满足：

- 条件明确
- 边界清楚
- 变量可观测
- 结论可执行
- 含义可解释

例如“成绩较好”不够清楚。

应改为：

平均成绩 ≥ 85



规则边界

规则边界是触发规则的临界条件。

例如：

订单金额 $> 10000 \Rightarrow$ 进入人工审核

这里 10000 就是规则边界。

边界可以来自制度规定，也可以通过数据分析确定。

边界设置过松或过严都会影响模型效果。

规则集合

实际问题通常不是一条规则，而是一组规则。
例如风控模型可能包括：

- 身份认证规则
- 金额阈值规则
- 登录异常规则
- 历史逾期规则
- 黑名单规则

规则集合共同决定最终结果。



规则链

规则链表示一个结论可以作为另一条规则的条件。
例如：

缺课次数 $>$ 总课时 $/3 \Rightarrow$ 出勤不合格

出勤不合格 $\Rightarrow$ 不能参加期末考试

于是可推出：

缺课次数 $>$ 总课时 $/3 \Rightarrow$ 不能参加期末考试

这就是规则之间的传递。

规则可解释性

逻辑规则建模的重要优点是可解释。

例如模型给出结论：

该订单需要人工审核。

解释可以是：

因为该订单金额超过 10000 元，且收货地址与历史地址不一致。

这种解释比单纯给出一个风险分数更容易被理解和接受。

规则与机器学习模型的关系

逻辑规则和机器学习模型并不是对立的。
常见结合方式包括：

- 规则作为前置过滤
- 规则作为后置校验
- 规则作为模型特征
- 规则用于解释模型输出
- 机器学习用于发现候选规则



案例一：学生毕业资格判断

设学生 x 的毕业资格由以下条件决定：

- 总学分达到要求
- 必修课全部通过
- 毕业论文合格
- 无严重处分记录

可建立规则：

学分合格 $\wedge$ 必修课合格 $\wedge$ 论文合格 $\wedge$ 无严重处分 $\Rightarrow$ 可以毕业

毕业资格规则拆解

可以进一步拆成多条规则：

总学分 $\geq 160 \Rightarrow$ 学分合格

所有必修课成绩 $\geq 60 \Rightarrow$ 必修课合格

论文成绩 $\geq 60 \Rightarrow$ 论文合格

学分合格 $\wedge$ 必修课合格 $\wedge$ 论文合格 $\Rightarrow$ 学业合格

这样规则结构更清楚，也便于检查。

案例二：课程推荐规则

面向学生选课，可以设计课程推荐规则。
例如：

已修高等数学 $\wedge$ 已修线性代数 $\Rightarrow$ 推荐数学建模

已修概率论 $\wedge$ 对数据分析感兴趣 $\Rightarrow$ 推荐机器学习导论

这类规则可用于构建简单的课程推荐系统。

课程推荐中的排除规则

推荐系统不仅要推荐，还要避免错误推荐。
例如：

未修先修课程 $\Rightarrow$ 不推荐后续课程

课程时间冲突 $\Rightarrow$ 不推荐同时选择

已修该课程 $\Rightarrow$ 不再推荐

排除规则可以提升推荐结果的合理性。



案例三：医学辅助诊断

设病人具有症状信息。
简单诊断规则可以写为：

发热 $\wedge$ 咳嗽 $\wedge$ 咽痛 $\Rightarrow$ 呼吸道感染可能

若加入风险因素：

发热 $\wedge$ 呼吸困难 $\wedge$ 血氧低 $\Rightarrow$ 需要紧急处理

医学规则强调可解释性，但实际应用必须结合专业医生判断。

医学规则的特点

医学辅助诊断规则通常具有以下特点：

- 规则需要专业知识支持
- 同一症状可能对应多种疾病
- 结论常常不是确定的
- 需要区分普通提示和紧急预警
- 不能仅凭单条规则做最终诊断

因此医学场景常使用带权规则和人工复核。



案例四：金融风控

设用户申请贷款。
常见风控规则包括：

黑名单用户 $\Rightarrow$ 拒绝

近一年逾期次数 $\geq 3 \Rightarrow$ 高风险

收入稳定 $\wedge$ 信用评分高 $\Rightarrow$ 低风险

风控规则强调合规、可解释和风险控制。



风控规则的优先级

风控模型中常见硬规则：

黑名单用户 $\Rightarrow$ 直接拒绝

即使该用户其他指标较好，也要优先执行。
普通规则可以用于评分：

信用评分高 $\Rightarrow$ 加分

负债率高 $\Rightarrow$ 减分

最终根据综合结果做判断。



案例五：电商订单异常检测

电商订单可能存在欺诈或异常行为。
规则示例：

订单金额 $>$ 历史均值 3 倍 $\Rightarrow$ 异常订单

短时间内多次下单 $\wedge$ 多次取消 $\Rightarrow$ 异常行为

收货地址频繁变化 $\wedge$ 支付设备异常 $\Rightarrow$ 高风险订单

这类规则常用于预警和人工审核。

案例六：智能客服

智能客服中的规则可以表示业务流程。

例如：

用户询问退款 $\Rightarrow$ 查询订单状态

订单已发货 $\Rightarrow$ 提示退货流程

订单未发货 $\Rightarrow$ 提示取消订单流程

规则建模可以保证客服回答符合业务流程。



智能客服中的意图识别

在智能客服中，机器学习模型可以识别用户意图。
逻辑规则负责控制后续流程。
例如：

意图 = 退款 $\wedge$ 订单已支付 $\wedge$ 未发货 $\Rightarrow$ 可以申请退款

意图 = 退款 $\wedge$ 已发货 $\Rightarrow$ 进入退货流程

这体现了模型识别与规则决策的结合。

案例七：交通信号控制

设路口车流量较大时，需要调整信号灯。
规则示例：

主路排队长度 $>$ 阈值 $\Rightarrow$ 延长主路绿灯

支路等待时间 $>$ 最大等待时间 $\Rightarrow$ 切换支路绿灯

紧急车辆接近 $\Rightarrow$ 优先放行

交通控制中，规则需要兼顾效率和安全。

案例八：排课问题

排课问题中有大量硬约束。
例如：

教师 A 同一时间不能上两门课

同一班级同一时间不能安排两门课

教室容量 $<$ 选课人数 $\Rightarrow$ 不能安排

这些规则必须严格满足，否则方案不可行。



排课中的软规则

排课除了硬约束，还有软规则。
例如：

尽量避免早八课程过多

尽量避免同一天课程过于集中

尽量将同一课程安排在固定教室

软规则不一定必须满足，但会影响方案质量。
这类问题常结合优化模型处理。



案例九：招聘简历筛选

简历筛选可以使用规则辅助。

例如：

专业匹配 $\wedge$ 技能匹配 $\Rightarrow$ 进入初筛

缺少必要资格证书 $\Rightarrow$ 不通过硬性筛选

项目经历相关 $\Rightarrow$ 增加匹配度

规则可以让筛选过程更透明。



案例十：垃圾邮件识别

垃圾邮件识别可以结合规则与模型。

规则示例：

包含大量异常链接 $\Rightarrow$ 可疑邮件

发件人域名异常 $\Rightarrow$ 可疑邮件

短时间群发大量邮件 $\Rightarrow$ 高风险邮件

这些规则可以作为模型输入特征，也可以作为直接拦截条件。

案例十一：知识图谱推理

知识图谱中存储实体及其关系。

例如：

父亲 (A,B)

表示 A 是 B 的父亲。

规则：

父亲 (x,y) $\Rightarrow$ 父母 (x,y)

又如：

父母 (x,y) $\wedge$ 父母 (y,z) $\Rightarrow$ 祖父母 (x,z)

通过规则可以推出新的关系。



案例十二：法律合规判断

法律合规问题中，规则具有强约束性质。
例如：

未实名认证 $\Rightarrow$ 不允许进行特定交易

缺少授权 $\Rightarrow$ 不允许访问敏感数据

这类规则通常不能由模型概率结果替代。



案例十三：工业设备预警

设设备具有温度、压力、振动等指标。

规则示例：

温度 $>$ 阈值 $\Rightarrow$ 温度异常

压力异常 $\wedge$ 振动异常 $\Rightarrow$ 高风险故障

连续异常时间 > 10 分钟 $\Rightarrow$ 触发报警

工业场景重视规则的稳定性和可解释性。

案例十四：推荐系统中的规则约束

推荐系统不仅考虑用户兴趣，也要满足规则。
例如：

用户已购买商品 $\Rightarrow$ 不再推荐同一商品

库存为 0 $\Rightarrow$ 不推荐

这些规则用于保证推荐结果合理、安全、合规。



案例十五：数学建模竞赛评分

也可以用规则描述竞赛评分。
例如：

模型假设合理 $\wedge$ 符号定义清楚 $\Rightarrow$ 基础分较高

有模型检验 $\wedge$ 有灵敏度分析 $\Rightarrow$ 加分

公式复杂但解释不足 $\Rightarrow$ 扣分

这说明逻辑规则可以用于评价体系建模。

规则模型的优点

逻辑规则建模具有以下优点：

- 易理解
- 易解释
- 易检查
- 能表达硬约束
- 适合小样本场景
- 便于与专家知识结合

因此它在 AI 系统中仍然非常重要。



规则模型的局限

逻辑规则建模也有局限：

- 规则过多时维护困难
- 难以覆盖所有特殊情况
- 阈值设置可能主观
- 对模糊问题表达能力有限
- 无法自动从大量数据中学习复杂模式

因此规则建模常与机器学习结合使用。



规则过拟合问题

规则也可能过拟合。

例如根据少量案例总结出过细规则：

地区 = A $\wedge$ 年龄 = 23 $\wedge$ 消费 = 某区间 $\Rightarrow$ 高风险

这种规则可能只适用于个别样本。

好的规则应具有一定普遍性，而不是只解释少数历史数据。

规则维护问题

现实业务会不断变化。

例如：

- 政策变化
- 用户行为变化
- 新风险类型出现
- 产品规则调整

因此规则库需要定期更新。

否则旧规则可能失效，甚至产生错误决策。



规则建模与决策树

决策树是一种可以产生规则的机器学习方法。
例如树中的一条路径：

年龄 $< 18 \wedge$ 消费金额 $> 5000 \Rightarrow$ 高风险

可以看作一条规则。
因此决策树常用于从数据中提取可解释规则。

规则建模与专家系统

专家系统是早期 AI 的重要形式。
它通常由三部分组成：

- 知识库：存储事实和规则
- 推理机：根据规则推出结论
- 解释模块：说明结论来源

现代 AI 系统中，专家系统思想仍然广泛存在。



规则建模的实际流程

实际进行逻辑规则建模时，可按以下流程：

- ① 明确问题目标
- ② 确定对象和属性
- ③ 收集规则来源
- ④ 将自然语言规则形式化
- ⑤ 设置规则优先级
- ⑥ 检查规则冲突
- ⑦ 用案例验证规则
- ⑧ 持续更新规则库



如何检验规则模型

规则模型可以从以下角度检验：

- 规则是否覆盖主要场景
- 规则是否存在冲突
- 规则边界是否合理
- 推理结果是否符合专家判断
- 错误案例是否可以解释

检验规则模型时，应同时关注准确性和解释性。



总结一：逻辑规则建模的本质

逻辑规则建模的本质是：

事实 + 规则 $\Rightarrow$ 结论

它把现实问题中的判断标准转化为形式化表达。
逻辑规则不是简单的“条件语句”，而是 AI 系统表达知识、执行推理和保证约束的重要工具。

总结二：核心建模要领

逻辑规则建模要重点把握：

- 对象是谁
- 属性是什么
- 条件如何判断
- 结论是什么
- 规则是否冲突
- 边界是否清楚
- 是否能够解释

每一条规则都应有现实依据。



总结三：规则与 AI 模型结合

现代 AI 建模中，逻辑规则常与数据模型结合。

- 数据模型负责从数据中学习模式
- 逻辑规则负责表达约束和知识
- 二者结合可以提升可解释性、安全性和可靠性

这也是 AI 建模从“纯数据驱动”走向“知识与数据融合”的重要方向。

课后思考

请思考以下问题：

- ① 如何为校园选课系统设计逻辑规则？
- ② 如何为网购订单异常检测设计规则？
- ③ 如何处理两条规则给出相反结论的情况？
- ④ 逻辑规则和机器学习模型各自适合什么场景？

尝试写出对象、属性、条件、结论和规则边界。



结束语

逻辑规则建模是 AI 建模中的基础方法之一。
它强调从现实知识出发，用清楚、可解释、可验证的规则描述判断过程。

现实知识 → 逻辑规则 → 推理结论

谢谢大家！