

非线性规划方法

连续系统与离散系统建模

谭忠

厦门大学数学科学学院

2025 年 7 月 29 日



厦門大學 数学科学学院
SCHOOL OF MATHEMATICAL SCIENCES XIAMEN UNIVERSITY

课程大纲

- ① 源头问题与当今应用
 - 源头问题
 - 当今应用
- ② 非线性规划思想与建模方法
 - 基本概念
 - 无约束非线性规划的解法
 - 约束非线性规划的解法
- ③ 案例分析
- ④ 作业



源头问题

非线性规划是 20 世纪 50 年代才开始形成的一门新兴学科。美国经济学家哈罗德·库恩和数学家阿尔伯特·塔克在 1948 年研究纳什均衡存在性证明时，遇到这样一个问题：如何从无数种可能的战略组合中，严格判定哪些策略能使博弈双方在资源约束下同时达到收益最大化？

传统拉格朗日乘数法因无法处理不等式约束宣告失败，1951 年 H.W. 库恩和 A.W. 塔克发表的《关于最优性条件》，是非线性规划正式诞生的一个重要标志。在 50 年代还得出了可分离规划和二次规划的多种解法，它们大都是以 G.B. 丹齐克提出的解线性规划的单纯形法为基础的。50 年代末到 60 年代末出现了许多解非线性规划问题的有效的算法，70 年代又得到进一步的发展。

源头问题

对于**有约束条件**的非线性规划问题，可以将其转化为**无约束条件**的非线性规划问题后再进行求解。

例. 有一块宽为 a 的薄塑料板，对称地把两边折起做成槽底宽 x_1 ，槽边 x_2 。欲使槽的横截面积 S 最大，槽边与水平的夹角 θ 的最优值是多少？





图 10.1

源头问题

分析：该问题要找出最优参数底宽 x_1 ，槽边 x_2 ，槽边与水平的夹角 θ ，使槽的横截面积 S 最大。所以目标函数为

$$\max S = (x_1 + x_2 \cos \theta) \cdot x_2 \sin \theta.$$

由于底边与两个斜边的总长度应等于塑料板宽度，因此约束条件为

$$x_1 + 2x_2 = a.$$

有许多最优化问题可以方便地将等式约束条件代入目标函数中，使原问题转换为无约束条件的最优化问题，便于求解。于是本例变为无约束条件的最优化问题时，目标函数为

$$\max S = (a - 2x_2 + x_2 \cos \theta) \cdot x_2 \sin \theta.$$

当今应用

非线性规划在工程、管理、经济、科研、军事等方面都有广泛的应用，为最优设计提供了有力的工具。许多实际问题如设计问题、经济平衡问题都属于非线性规划的范畴。非线性规划扩大了数学规划的应用范围，同时也给数学工作者提出了许多基本理论问题，使数学中的如凸分析、数值分析等也得到了发展。

面向世界科技前沿

1. 量子计算与新材料设计

- 在量子比特控制中，通过非线性规划优化脉冲序列，最大化量子门保真度（目标函数为复杂的量子态演化方程）
- 新材料分子结构优化中，求解薛定谔方程的能量极小值点（非凸优化问题），如催化剂活性位点设计

2. 高能物理与天体观测

- 大型强子对撞机（LHC）数据重建：通过非线性最小二乘法拟合粒子轨迹（约束为探测器几何边界）
- 望远镜阵列调度优化：最大化观测效率（目标为科学价值函数，约束为天体可见时间窗口）

3. 人工智能前沿

- 深度学习模型训练本质是非线性规划（如 Adam 算法优化损失函数）
- 神经架构搜索（NAS）中自动设计网络结构，需在参数量、精度、延迟间权衡（多目标非线性优化）

面向经济主战场

1. 智慧能源系统

- 电力调度：优化风电/光伏出力与火电成本（目标为总发电成本最小，约束为电网潮流方程，呈非线性）
- 微电网运行：考虑蓄电池充放电非线性损耗模型，实现经济—环保多目标优化

2. 智能制造与供应链

- 半导体晶圆生产调度：解决带时间窗约束的混合整数非线性规划（MINLP），最小化制造周期
- 物流路径优化：车辆路径问题（VRP）中引入道路拥堵函数（非线性时间成本），提升配送效率

3. 金融科技

- 投资组合优化：在收益率波动率模型中引入非线性交易成本与风险价值（VaR）约束
- 衍生品定价：求解 Black-Scholes 偏微分方程转化为非线性规划问题

面向国家重大需求

1. 航空航天与国防

- 导弹轨迹优化：燃料最省路径满足终端约束（**微分方程约束**的非线性最优控制问题）
- 卫星星座部署：优化卫星轨道参数以最大化覆盖区域（目标函数含**三角函数非线性项**）

2. 资源勘探与灾害预警

- 石油储层反演：通过**非线性最小二乘**拟合地震波数据，求解地下参数分布
- 洪水演进模拟：基于圣维南方程组（非线性偏微分方程）优化泄洪方案

3. 粮食安全与农业现代化

- 精准灌溉优化：耦合作物生长模型（非线性生理过程）与水肥成本，实现亩产最大化
- 农机调度：在复杂地块约束下优化收割路径（**非欧几里得距离约束**）

面向人民生命健康

1. 新药研发与医学影像

- 药物分子动力学模拟：寻找蛋白质—配体结合能全局最小值（高维非凸优化）。
- MRI 图像重建：压缩感知理论中的非线性正则化模型（如 L_1 范数稀疏约束）

2. 疾病预测与医疗资源调配

- 流行病传播模型（如 SEIR）参数拟合：非线性最小二乘校准模型与实际数据。
- 重症床位分配：在时空约束下最大化救治成功率（目标函数为生存率非线性模型）

3. 个性化治疗与健康管理

- 癌症放疗计划优化：调整射线剂量分布（目标为肿瘤区最大化/正常组织最小化，约束为物理剂量方程）
- 可穿戴设备数据分析：基于非线性时序模型预警心血管异常

非线性规划的一般形式

非线性规划

所谓**非线性规划**，是指目标函数或约束条件中包含有**非线性函数**的一类**最优化问题**。非线性规划问题简记为 NLP (nonlinear programming) 问题。

一. 非线性规划的一般形式

$$\min z = f(x) \quad (2.1)$$

$$\text{s.t.} \quad \begin{cases} h_j(x) = 0 & j = 1, 2, \dots, q \\ g_i(x) \geq 0 & i = 1, 2, \dots, p \end{cases} \quad (2.2)$$

其中 $x = (x_1, x_2, \dots, x_N)^T$ 为 N 维欧氏空间中的向量点， T 表示转置， $f(x)$ 为目标函数， $h_j(x)$ 为 q 个等式约束条件， $g_i(x)$ 为 p 个不等式约束条件，包括**资源约束**和**变量约束**。

非线性规划的标准式

可行解和最优解

把满足上述非线性规划的一般形式中的条件的点称为可行点 (可行解), 所有可行点的集合称为可行域, 即

$$K = \{x = (x_1, x_2, \dots, x_N)^T \mid g_i(x) \geq 0, i = 1, 2, \dots, p; h_j(x) = 0, j = 1, 2, \dots, q\}$$

若某个可行解使目标函数为最小, 即使 (2.1) 成立, 就称它为最优解。

二. 非线性规划的标准式: NLP 模型的标准形式有两个要求

1. 目标函数为极小形式, 若原 NLP 模型为 $\max f(x)$ 形式, 应变为 $\min[-f(x)] = \min f'(x)$
2. 约束条件为 $\geq$ 或 $=$ 或 $\leq$ 号。这里有两点值得注意: 一是原 NLP 模型的不等式约束不必变为等式; 二是 $\leq$ 仅需用“-1”乘该约束的两端, 即可将这个约束变成 $\geq$ 的形式。

非线性规划模型的特殊类型

三. 非线性规划模型的特殊类型

- (1) 按约束条件 $g_i(x)$ (或 $h_j(x)$) 有与无, 分为有约束 NLP 问题和无约束 NLP 问题。
- (2) 有约束 NLP 问题的目标函数可以是非线性函数或线性函数 (此类 NLP 问题的约束条件中起码有一个约束条件是非线性函数)。
- (3) 无约束 NLP 问题的目标函数必须是非线性函数, 其中目标函数为单变量的非线性函数, 称为 NLP 的一维无约束优化问题, 又称一维搜索问题; 若目标函数有多个变量, 称为 NLP 的多维无约束优化问题, 或称多维无约束极值问题。

非线性规划模型的特殊类型

- (4) 二次规划：有约束的 NLP 问题中，目标函数为二次函数，约束条件全为线性函数，称为二次规划
- (5) 几何规划：NLP 问题中，目标函数及约束条件的不等式具有非线性的多元多项式形式，如

$$\begin{aligned} \min \quad & f(x) = 6 + 3x_1 - 8x_2 + 7x_3 + 2x_1x_2 - 3x_1x_3 - 9x_2^2 + x_3^2 \\ \text{s.t.} \quad & g(x) = 0.33x_2x_3 + 3x_1^{-0.5}x_2^{-0.75}x_3^{-1} + 4.5x_2^{0.5}x_3^{-1}x_4^{-0.5} - 1 \geq 0 \\ & x_1, x_2, x_3, x_4, > 0 \end{aligned}$$

凸集与凸函数

四. 凸规划

1. 凸集与凸函数的定义

凸集

设 K 是 N 维欧氏空间的一点集, 若任意两点 $x_1 \in K, x_2 \in K$ 的连线上的所有点 $\alpha x_1 + (1 - \alpha)x_2 \in K$ ($0 \leq \alpha \leq 1$), 则称 K 为凸集。

实心圆、实心球体、实心立方体等都是凸集, 圆环不是凸集。从直观上讲, 凸集没有凹入部分, 其内部没有空洞。任何两个凸集的交集是凸集。

凸函数

给定函数 $f(x)$ ($x \in D \subset R$), 若 $\forall x_1, x_2 \in D, \lambda \in [0, 1]$, 有

$$f(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda f(x_1) + (1 - \lambda)f(x_2)$$

则称 $f(x)$ 为 D 上的凸函数

凸函数

特别地, 若 $f(\lambda x_1 + (1-\lambda)x_2) < \lambda f(x_1) + (1-\lambda)f(x_2)$, 则称 $f(x)$ 为 D 上的严格凸函数。

将上述两式中的不等号反向, 即可得到凹函数和严格凹函数的定义。显然, 若函数 $f(x)$ 是凸函数 (严格凸函数), 则 $-f(x)$ 一定是凹函数 (严格凹函数)。

凸函数和凹函数的几何意义十分明显, 若函数图形上任两点的连线处处都不在这个函数图形的下方, 它当然是凸的。线性函数既可看作凸函数, 也可看作凹函数。

2. 凸函数的性质

- **性质 1:** 定义在凸集上的有限个凸函数的非负线性组合仍为凸函数。
- **性质 2:** 设 $f(x)$ 为定义在凸集 K 上的凸函数, 则对任一实数 α , 集合

$$S_\alpha = \{x | x \in K, f(x) \leq \alpha\}$$

是凸集 (S_α 称为水平集)。

函数凸性的判定

3. 函数凸性的判定

怎样判断一个函数是凸函数？首先可以直接依据定义去判别。对于可微函数，也可利用下述两个判别定理。

一阶条件

设 K 为 N 维欧氏空间 $\mathbb{R}^N$ 上的开凸集， $f(x)$ 在 K 上具有一阶连续偏导数，则 $f(x)$ 为 K 上的凸函数的充要条件是：对任意两个不同点 $x_1, x_2 \in K$ ，恒有

$$f(x_2) \geq f(x_1) + \nabla f(x_1)^T (x_2 - x_1). \quad (2.3)$$

函数凸性的判定

证明:

- 必要性: 设 $f(x)$ 为 K 上的凸函数, 则对任何的 t ($0 < t < 1$) 有

$$f(tx_2 + (1-t)x_1) \leq tf(x_2) + (1-t)f(x_1),$$

于是

$$\frac{f(x_1 + t(x_2 - x_1)) - f(x_1)}{t} \leq f(x_2) - f(x_1).$$

令 $t \rightarrow 0^+$, 上式左端的极限为 $\nabla f(x_1)^T(x_2 - x_1)$, 即

$$f(x_2) \geq f(x_1) + \nabla f(x_1)^T(x_2 - x_1).$$

函数凸性的判定

- **充分性：**任取 $x_1, x_2 \in K$ ，现令

$$x = tx_1 + (1-t)x_2, \quad 0 < t < 1,$$

分别令 x_1 和 x_2 为 (2.3) 中的 x_2 ，令 x 为 (2.3) 中的 x_1 ，则

$$f(x_1) \geq f(x) + \nabla f(x)^T (x_1 - x).$$

$$f(x_2) \geq f(x) + \nabla f(x)^T (x_2 - x).$$

用 t 乘上面的第一式，用 $(1-t)$ 乘上面的第二式，然后两端相加

$$\begin{aligned} tf(x_1) + (1-t)f(x_2) &\geq f(x) + \nabla f(x)^T [tx_1 - tx + (1-t)(x_2 - x)] \\ &= f(x) = f(tx_1 + (1-t)x_2) \end{aligned}$$

从而可知 $f(x)$ 为 K 上的凸函数。若 (2.3) 为严格不等式，它就是严格凸函数的充要条件。

Hessian 矩阵

凸函数的定义, 本质上是说凸函数上两点间的线性插值不低于这个函数的值; 而上述定理则是说基于某点导数的线性近似不高于这个函数的值或曲线上各点的切线在曲线之下。

海赛 (Hessian) 矩阵

多元函数 $f(x)$ ($x = (x_1, x_2, \dots, x_N)^T$) 的二阶偏数组成的矩阵称为其海赛 (Hessian) 矩阵, 记为

$$\nabla^2 f(x) = \begin{pmatrix} \frac{\partial^2 f(x)}{\partial x_1^2} & \frac{\partial^2 f(x)}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f(x)}{\partial x_1 \partial x_N} \\ \frac{\partial^2 f(x)}{\partial x_2 \partial x_1} & \frac{\partial^2 f(x)}{\partial x_2^2} & \cdots & \frac{\partial^2 f(x)}{\partial x_2 \partial x_N} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f(x)}{\partial x_N \partial x_1} & \frac{\partial^2 f(x)}{\partial x_N \partial x_2} & \cdots & \frac{\partial^2 f(x)}{\partial x_N^2} \end{pmatrix}$$

函数凸性的判定

二阶条件

设 K 为 N 维欧氏空间 $\mathbb{R}^N$ 上的开凸集, $f(x)$ 在 K 上具有二阶连续偏导数, 则 $f(x)$ 为 K 上的凸函数的充要条件是: $f(x)$ 的海赛矩阵 $\nabla^2 f(x)$ 在 K 上处处半正定。

函数凸性的判定

例. 试证明 $f(x) = -x_1^2 - x_2^2$ 为凹函数。

证明:

- 证法一: 对于任意指定两点 a_1 和 a_2 , 考虑下式

$$-[ta_1 + (1-t)a_2]^2 \geq t(-a_1^2) + (1-t)(-a_2^2)$$

是否成立? 展开后即看

$$a_1^2(t-t^2) - 2a_1a_2(t-t^2) + a_2^2(t-t^2) \geq 0$$

是否成立? 简化后得

$$(t-t^2)(a_1-a_2)^2 \geq 0.$$

由于 $0 < t < 1$, 故 $t-t^2 > 0$. 因此上式显然成立, 从而利用定义证明 $f_1(x_1) = -x_1^2$ 为凹函数。同理可证 $f_2(x_2) = -x_2^2$ 为凹函数。根据性质 2, $f(x) = -x_1^2 - x_2^2$ 也为凹函数。

函数凸性的判定

- **证法二：** 用一阶条件证明。任意选取两点 $X^1 = (a_1, b_1)^T$, $X^2 = (a_2, b_2)^T$, 则

$$f(X^1) = -a_1^2 - b_1^2, \quad f(X^2) = -a_2^2 - b_2^2,$$
$$\nabla f(x) = (-2x_1, -2x_2)^T, \quad \nabla f(X^1) = (-2a_1, -2b_1)^T.$$

因此 (2.3) 等价于

$$-a_2^2 - b_2^2 \leq -a_1^2 - b_1^2 + (-2a_1, -2b_1) \begin{pmatrix} a_2 - a_1 \\ b_2 - b_1 \end{pmatrix},$$
$$\Leftrightarrow -a_2^2 - b_2^2 \leq -a_1^2 - b_1^2 - 2a_1(a_2 - a_1) - 2b_1(b_2 - b_1),$$

函数凸性的判定

即

$$\begin{aligned} & -(a_2^2 - 2a_1a_2 + a_1^2) - (b_2^2 - 2b_1b_2 + b_1^2) \leq 0, \\ \Leftrightarrow & -(a_2 - a_1)^2 - (b_2 - b_1)^2 \leq 0. \end{aligned}$$

不管 a_1, a_2, b_1, b_2 取什么值, 上式均显然成立, 从而得证。

函数凸性的判定

- 证法三：用二阶条件证明。由于

$$\begin{aligned}\frac{\partial f(x)}{\partial x_1} &= -2x_1, & \frac{\partial f(x)}{\partial x_2} &= -2x_2, \\ \frac{\partial^2 f(x)}{\partial x_1^2} &= -2 < 0, & \frac{\partial^2 f(x)}{\partial x_2^2} &= -2 < 0, \\ \frac{\partial^2 f(x)}{\partial x_1 \partial x_2} &= \frac{\partial^2 f(x)}{\partial x_2 \partial x_1} = 0.\end{aligned}$$

因此

$$|\nabla^2 f(x)| = \begin{vmatrix} -2 & 0 \\ 0 & -2 \end{vmatrix} = 4 > 0,$$

其海赛矩阵处处负定，故 $f(x)$ 为 (严格) 凹函数。

NLP 的凸规划

NLP 的凸规划

对非线性规划问题 NLP, 若 $f(x)$ 为 K 上的凸函数, $g_i(x)$ 为 $\mathbb{R}^N$ 上的凹函数 ($-g_i(x)$ 为 $\mathbb{R}^N$ 上的凸函数), $h_j(x)$ 为 $\mathbb{R}^N$ 上的线性函数, 则称 NLP 为凸规划。

可以证明上述凸规划的可行域为凸集, 其局部最优解即为全局最优解, 而且其最优解的集合形成一个凸集。当凸规划的目标函数 $f(x)$ 为严格凸函数时, 其最优解必定唯一 (假定最优解存在)。由此可见, 凸规划是一类比较简单而又具有重要理论意义的非线性规划。由于线性函数既可视作凸函数, 又可视作凹函数, 故线性规划也属于凸规划。

NLP 的凸规划

例. 试分析非线性规划

$$\begin{cases} \min f(x) = x_1^2 + x_2^2 - 4x_1 + 4, \\ g_1(x) = x_1 - x_2 + 2 \geq 0, \\ g_2(x) = -x_1^2 + x_2 - 1 \geq 0, \\ x_1, x_2 \geq 0. \end{cases}$$



NLP 的凸规划

解: $f(x)$ 和 $g_2(x)$ 的海赛矩阵的行列式分别是

$$|H| = \begin{vmatrix} \frac{\partial^2 f(x)}{\partial x_1^2} & \frac{\partial^2 f(x)}{\partial x_1 \partial x_2} \\ \frac{\partial^2 f(x)}{\partial x_2 \partial x_1} & \frac{\partial^2 f(x)}{\partial x_2^2} \end{vmatrix} = \begin{vmatrix} 2 & 0 \\ 0 & 2 \end{vmatrix} = 4 > 0,$$
$$|G| = \begin{vmatrix} \frac{\partial^2 g_2(x)}{\partial x_1^2} & \frac{\partial^2 g_2(x)}{\partial x_1 \partial x_2} \\ \frac{\partial^2 g_2(x)}{\partial x_2 \partial x_1} & \frac{\partial^2 g_2(x)}{\partial x_2^2} \end{vmatrix} = \begin{vmatrix} -2 & 0 \\ 0 & 0 \end{vmatrix} = 0.$$

根据二阶条件知 $f(x)$ 为严格凸函数, $g_2(x)$ 为凹函数。由于其他约束条件均为线性函数, 所以这是一个凸规划, 其最优点为 $X^* = (0.58, 1.34)'$, 目标函数的最优值为 $f(X^*) = 3.8$

最优解定义与结论

无约束非线性规划的解法:

一. 最优解定义与结论

考虑无约束非线性规划问题:

$$NLP: \min z = f(x)$$

其中 $x = (x_1, x_2, \dots, x_N)^T$, 显然无约束 NLP 问题就是一个无条件函数的极值问题。

局部最优解

设 $X^* \in D$, 若存在 $\delta > 0$ 使得对一切 $X \in D, \|X - X^*\| < \delta$, 都有 $f(X^*) \leq f(X)$, 则称 X^* 是 $f(X)$ 在 D 上的**局部极小值点 (局部最优解)**。特别地当 $X \neq X^*$ 时, 若 $f(X^*) < f(X)$, 则称 X^* 是 $f(X)$ 在 D 上的**严格局部极小值点 (严格局部最优解)**。

全局最优解

全局最优解

设 $X^* \in D$, 若对任意的 $X \in D$, 都有 $f(X^*) \leq f(X)$, 则称 X^* 是 $f(X)$ 在 D 上的全局极小值点 (全局最优解)。特别地当 $X \neq X^*$ 时, 若 $f(X^*) < f(X)$, 则称 X^* 是 $f(X)$ 在 D 上的严格全局极小值点 (严格全局最优解)。

函数 $f(x) = f(x_1, x_2, \dots, x_N)$ 的一阶导数 $\nabla f(x) = \left(\frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2}, \dots, \frac{\partial f(x)}{\partial x_N} \right)^T$ 称为其梯度, 记 $f(x)$ 在点 $x^0 = (x_1^0, x_2^0, \dots, x_N^0)^T$ 处的梯度为

$$\nabla f(x^0) = \left(\frac{\partial f(x^0)}{\partial x_1}, \frac{\partial f(x^0)}{\partial x_2}, \dots, \frac{\partial f(x^0)}{\partial x_N} \right)^T.$$

在微积分学中, 有如下一元函数取极值的必要条件: 可导的一元函数 $f(x)$ 在 x^* 处取极值, 则 $f'(x^*) = 0$ (极值点必为稳定点或驻点)。此结论可推广到多元函数的情形。

判定条件

必要条件

设函数 $f(x)$ 可微, 若 x^* 为无约束非线性规划问题

$$NLP: \min z = f(x)$$

的局部最优解, 则 $\nabla f(x^*) = 0$ (稳定点或驻点)。

充分条件

若梯度 $\nabla f(x^*) = 0$, 且海赛矩阵 $\nabla^2 f(x^*)$ 正定, 则 x^* 为无约束非线性规划问题

$$NLP: \min z = f(x)$$

的局部最优解。

判定条件

充要条件

若 $f(x)$ 为可微的凸函数，则梯度 $\nabla f(x^*) = 0$ 的充要条件是 x^* 为无约束非线性规划问题

$$NLP: \min z = f(x)$$

的整体最优解。

无约束 NLP 问题

例. 求解无约束 NLP 问题: $\min f(x) = x_1^2 + 4x_2^2 + x_3^2 - 2x_1$
解:

$$\nabla f(x) = \left(\frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2}, \frac{\partial f(x)}{\partial x_3} \right)^T = (2x_1 - 2, 8x_2, 2x_3)^T,$$
$$\nabla^2 f(x) = \begin{pmatrix} 2 & 0 & 0 \\ 0 & 8 & 0 \\ 0 & 0 & 2 \end{pmatrix}$$

令 $\nabla f(x) = 0$, 得 $f(x)$ 的驻点为 $x^* = (1, 0, 0)^T$. 又显然 $\nabla^2 f(x)$ 正定, 故 $f(x)$ 为凸函数, NLP 为凸规划, 因此 $x^* = (1, 0, 0)^T$ 为 NLP 的局部最优解, 当然也是整体最优解。

无约束 NLP 问题

对于定义在凸集上的凸函数来说, 它的极小值就等于其最小值。

定理

若 $f(x)$ 为定义在凸集 K 上的凸函数, 则它的任一极小点就是它在 K 上的最小点 (全局极小点), 而且它的极小点形成一个凸集。

证明: 设 x^* 是一个局部极小点, 则对于充分小的邻域 $N_\delta(x^*)$ 中的一切 x , 均有

$$f(x) \geq f(x^*)$$

令 Y 是 K 中的任一点, 对于充分小的 λ , $0 < \lambda < 1$ 有

$$(1-\lambda)x^* + \lambda Y \in N_\delta(x^*),$$

从而

$$f((1-\lambda)x^* + \lambda Y) \geq f(x^*).$$

无约束 NLP 问题

由于 $f(x)$ 为凸函数, 故

$$(1-\lambda)f(x^*) + \lambda f(Y) \geq f((1-\lambda)x^* + \lambda Y),$$

结合上述两个不等式, 移项后除以 λ 得到

$$f(Y) \geq f(x^*).$$

这就是说 x^* 是全局极小点。由性质 2, 所有极小点的集合形成一个凸集。

无约束 NLP 问题

定理 2.7

设 $f(x)$ 是定义在凸集 K 上的可微凸函数, 若存在点 $x^* \in K$, 使得对于所有的 $x \in K$ 有

$$\nabla f(x^*)^T (x - x^*) \geq 0, \quad (2.5)$$

则 x^* 是 $f(x)$ 在 K 上的最小点 (全局极小点)。

证明: 根据定理 2.1,

$$f(x) \geq f(x^*) + \nabla f(x^*)^T (x - x^*),$$

如此, 对所有 $x \in K$ 有

$$f(x) \geq f(x^*).$$

显然, 上述求解无约束非线性规划问题的微分法是有局限性的, 因为目标函数未必可微。因此, 需寻求其他方法。

下降迭代算法

二. 下降迭代算法

为了求某可微函数 (假定无约束) 的最优解, 根据前面的叙述可如下进行: 令该函数的梯度等于零, 由此求得稳定点, 然后用充分条件进行判别, 求出所要的解。对一元函数或简单的多元函数, 这样做有时是可行的, 但对一般 N 元函数 $f(x)$ 来说, 由梯度 $\nabla f(x) = 0$ 得到的常是一个很难求解的非线性方程组。对不可微函数, 不能使用这样的方法。为此, 常直接使用迭代法。

迭代法的基本思想是: 为了求函数 $f(x)$ 的最优解, 首先给定一个初始估计 x^0 , 然后按某种规则 (即算法) 找出比 x^0 更好的解 x^1 , 对极小化问题, $f(x^1) < f(x^0)$; 对极大化问题, $f(x^1) > f(x^0)$; 再按此种规则找出比 x^1 更好的解 $x^2, \dots$, 如此即可得到一个解的序列 $\{x^k\}$ 。若这个解序列有极限 x^* , 即

$$\lim_{k \rightarrow \infty} \|x^k - x^*\| = 0,$$

则称它收敛于 x^* 。

下降迭代算法

若这算法是有效的，那么它所产生的解序列将收敛于该问题的最优解。不过由于计算机只能进行有限次迭代，一般只能得到近似解。当满足所要求的精度时，即可停止迭代。若由某算法所产生的解的序列 $\{x^k\}$ 使目标函数值 $f(x^k)$ 逐步减少，就称这算法为下降算法。

现假定已迭代到点 x^k ，若从 x^k 出发沿任何方向移动都不能使目标函数值下降，则 x^k 是一局部极小点，迭代停止。若从 x^k 出发至少存在一个方向可使目标函数值有所下降，则可选定能使目标函数值下降的某方向 P^k ，沿这个方向适当迈进一步，得到下一个迭代点 x^{k+1} ，并使

$$f(x^{k+1}) < f(x^k).$$

这相当于在射线 $x = x^k + \lambda P^k$ 上选定新点

$$x^{k+1} = x^k + \lambda_k P^k,$$

其中 P^k 称为搜索方向， λ_k 称为步长或步长因子。

下降迭代算法

下降迭代算法的步骤可总结如下：

- (1) 选定某一初始点 x^0 ，并令 $k := 0$ ；
- (2) 确定搜索方向 P^k ；
- (3) 从 x^k 出发，沿方向 P^k 求步长 λ_k ，以产生下一个迭代点 x^{k+1} ；
- (4) 检查得到的新点 x^{k+1} 是否为极小点或近似极小点。若是，则停止迭代。否则，令 $k := k + 1$ ，转回 (2) 继续进行迭代。

下降迭代算法

在以上步骤中，选取搜索方向 P^k 是最关键的一步，各种算法的区分主要在于确定搜索方向的方法不同。

确定步长 λ_k 可选用不同的方法。最简单的一种是令它等于某一常数 (例如令 $\lambda_k = 1$)，这样做计算简便，但不能保证使目标函数值下降。第二种称为可接受点算法，只要能使目标函数值下降，可任意选取步长 λ_k 。第三种方法是基于沿搜索方向使目标函数值下降最多，即沿射线 $x = x^k + \lambda P^k$ 求目标函数的最小值：

$$\lambda_k: \min f(x^k + \lambda P^k).$$

由于这项工作是求以 λ 为变量的一元函数 $f(x^k + \lambda P^k)$ 的极小点 λ_k ，故常称这一过程为 (最优) 一维搜索或线搜索，这样确定的步长为最佳步长。

一维搜索有十分重要的性质：在搜索方向上所得最优点处的梯度和该搜索方向正交。

下降迭代算法

定理 2.8

设目标函数 $f(x)$ 具有一阶连续偏导数, x^{k+1} 按下述规则产生 λ_k

$$\begin{cases} \lambda_k : \min f(x^k + \lambda P^k), \\ x^{k+1} = x^k + \lambda_k P^k, \end{cases}$$

则有

$$\nabla f(x^{k+1})^\top P^k = 0.$$

下降迭代算法

对一个好的算法，不仅要求它产生的点列能收敛到问题的最优解，还要求具有较快的收敛速度。设序列 $\{x^k\}$ 收敛于 x^* ，若存在与迭代次数 k 无关的数 $0 < \beta < \infty$ 和 $\alpha \geq 1$ ，使 k 从某个 $k_0 > 0$ 开始都有

$$\|x^{k+1} - x^*\| \leq \beta \|x^k - x^*\|^\alpha$$

成立，就称 $\{x^k\}$ 收敛的阶为 α ，或 $\{x^k\}$ **α 阶收敛**。当 $\alpha = 2$ 时，称为二阶收敛，也可说 $\{x^k\}$ 具有二阶收敛速。当 $1 < \alpha < 2$ 时，称**超线性收敛**。当 $\alpha = 1$ 且 $0 < \beta < 1$ 时，称**线性收敛或一阶收敛**。

梯度的性质

三. 梯度的性质

定理 2.9

函数 $f(x)$ 在点 x^0 处的负梯度 $-\nabla f(x^0)$ 是 $f(x)$ 在点 x^0 处下降最快的方向。

定理 2.10

若梯度 $-\nabla f(x^0) = 0$, 则 $f(x)$ 在点 x^0 处沿负梯度方向 $-\nabla f(x^0)$ 不会再下降, 故 x^0 为 NLP 的最优解。

注: 为增强算法可操作性, 判定 “ $\nabla f(x^0) = 0$ ” 可等价地转化为判定 “ $\nabla f(x^0) \approx 0$ ”。

最速下降法

四. 最速下降法

在求解无约束非线性规划问题即无约束极值问题 (2.4) 时常使用迭代法。迭代法可大体分为两大类：一类需要用到函数导数，即用到了函数的解析性质，故称为**解析法**；另一类在迭代过程中仅用到函数值，而不要求函数的解析性质，这类方法称为**直接法**。一般说来，直接法的收敛速度较慢，只是在变量较少时才适用。但是直接法的迭代步骤简单，特别是当目标函数的解析表根本不存在，这时解析法就无能为力了。

本节只介绍在求解无约束极值问题的解析法中最基本的一种数值方法——**梯度法**。

最速下降法

假定无约束极值问题 (2.4) 式中的目标函数 $f(x)$ 有一阶连续偏导数, 具有极小点 x^* 。以 x^k 表示极小点的第 k 次近似, 为了求其第 $k+1$ 次近似点 x^{k+1} , 我们在 x^k 点沿方向 P^k 做射线

$$x = x^k + \lambda P^k \quad (\lambda \geq 0).$$

现将 $f(x)$ 在 x^k 点处展成泰勒级数

$$f(x) = f(x^k + \lambda P^k) = f(x^k) + \lambda \nabla f(x^k)^\top P^k + o(\lambda),$$

其中 $\lim_{\lambda \rightarrow 0} \frac{o(\lambda)}{\lambda} = 0$ 。对于充分小的 λ , 只要

$$\nabla f(x^k)^\top P^k < 0, \tag{2.6}$$

即可保证 $f(x^k + \lambda P^k) < f(x^k)$ 。这时若取

$$x^{k+1} = x^k + \lambda P^k,$$

就能使目标函数得到改善。

最速下降法

现考察不同的方向 P^k 。假定 P^k 的模一定 (且不为零), 并设 $f(x^k) \neq 0$ (否则 x^k 是稳定点), 使 (2.6) 成立的 P^k 有无限多个。为了使目标函数值能得到尽量大的改善, 必须寻求使 $\nabla f(x^k)^\top P^k$ 取最小值的 P^k 。由线性代数知道

$$\nabla f(x^k)^\top P^k = \|\nabla f(x^k)\| \cdot \|P^k\| \cos \theta,$$

式中 θ 为向量 $\nabla f(x^k)$ 与 P^k 的夹角。当 P^k 与 $\nabla f(x^k)$ 反向时, $\theta = 180^\circ$ 且 $\cos \theta = -1$ 。这时 (2.6) 成立, 而且其左端取最小值。我们称方向

$$P^k = -\nabla f(x^k)$$

为**负梯度方向**, 它是使函数值下降最快的方向 (在 x^k 的某一小范围内)。为了得到下一个近似极小点, 在选定了搜索方向之后, 还要确定步长 λ 。当采用可接受点算法时, 就是取某一 λ 进行试算, 看是否满足不等式

$$f(x^k - \lambda \nabla f(x^k)) < f(x^k). \quad (2.7)$$

最速下降法

若上述不等式成立，就可以迭代下去。否则，缩小 λ 使满足不等式 (2.7)。由于采用负梯度方向，满足 (2.7) 的 λ 总是存在的。另一种方法是通过在负梯度方向的一维搜索来确定使 $f(x^k)$ 最小的 λ_k ，这种梯度法就是所谓**最速下降法**。

最速下降法的**基本思想**如下：给定初始点 x^0 ，若 $\nabla f(x^0) = 0$ ，则 x^0 即为 NLP 的最优解；否则 $f(x)$ 在点 x^0 处沿负梯度方向 $-\nabla f(x^0)$ 是 $f(x)$ 在点 x^0 处下降最快的方向。于是，求解 NLP $\Leftrightarrow$ 在点 x^0 处沿负梯度方向 $-\nabla f(x^0)$ 求函数 $f(x)$ 的最小值 $\Leftrightarrow$ 求解极值问题

$$P: \min f(x^0 - \lambda \nabla f(x^0)),$$

其中 λ 为步长。这里 P 是一个以 λ 为自变量的一元函数的极值问题，可利用微积分知识求解。设 P 的极值点为 λ_0 (最优步长)，令 $x^1 := x^0 - \lambda_0 \nabla f(x^0)$ ，由定理易证 $f(x^1) < f(x^0)$ ，重复上述步骤。

算法步骤

算法步骤:

步骤 1. 取初始点 x^0 及允许误差 $\varepsilon > 0$, 令 $k := 0$

步骤 2. 计算 $P^k = -\nabla f(x^k)$

步骤 3. 若 $\|P^k\| \leq \varepsilon$, 则 x^k 即为 NLP 的最优解, 结束步骤; 否则, 转入步骤 4

步骤 4. 求解极值问题 $\min f(x^k + \lambda P^k)$, 得到极值点 λ_k

步骤 5. 令 $x^{k+1} := x^k + \lambda_k P^k$, $k := k + 1$, 转入步骤 2

最速下降法的算法模式实质上是一种特定形式的迭代法, 其中 x^0 为初始点, P^k 为搜索方向, 即下降方向, 是区别不同算法的主要标志, λ_k 为步长, $x^{k+1} := x^k + \lambda_k P^k$ 为迭代格式。

最速下降法

例. 用最速下降法求解无约束非线性规划问题 NLP:

$$\min z = (x_1 - 1)^2 + 4(x_2 - 1)^2,$$

取初始点 $x^0 = (1, 0)'$, 允许误差 $\varepsilon = 0.01$

解:

(1)

$$f(x) = (x_1 - 1)^2 + 4(x_2 - 1)^2, \quad \nabla f(x) = (2(x_1 - 1), 8(x_2 - 1))',$$

$$P^0 = -\nabla f(x^0) = -(0, -8)' = (0, 8)'$$

(2)

$$\|P^0\| = \sqrt{0^2 + 8^2} = 8 > \varepsilon$$

最速下降法

(3)

$$\begin{aligned}x^0 + \lambda P^0 &= (1, 0)' + \lambda (0, 8)' = (1, 8\lambda)', \\f(x^0 + \lambda P^0) &= (1 - 1)^2 + 4(8\lambda - 1)^2 = 4(8\lambda - 1)^2\end{aligned}$$

求得极值点 $\lambda = \frac{1}{8}$, 代入 $x^0 + \lambda P^0 = (1, 1)' = x^1$

(4)

$$\begin{aligned}P^1 &= -\nabla f(x^1) = -(0, 0)' = (0, 0)', \\ \|P^1\| &= \sqrt{0^2 + 0^2} = 0 < \varepsilon,\end{aligned}$$

所以最优解为 $x^1 = (1, 1)'$

约束非线性规划的解法

约束非线性规划的解法:

考虑约束非线性规划问题 (2.1)-(2.2), 可行域 $K = \{x = (x_1, x_2, \dots, x_N)' \mid g_i(x) \geq 0, i = 1, 2, \dots, p; h_j(x) = 0, j = 1, 2, \dots, q\}$

NLP 的最优解

对非线性规划问题 (2.1)-(2.2) 及 $x^* \in K$, 若 $\forall x \in K$, 有 $f(x^*) \leq f(x)$, 则称 x^* 为 NLP 的**整体最优解**, $f(x^*)$ 为 NLP 的 **(整体) 最优值**; 若在 x^* 的某邻域内, 有 $f(x^*) \leq f(x)$, 则称 x^* 为 NLP 的**局部最优解**, $f(x^*)$ 为 NLP 的 **局部最优值**。

约束非线性规划的解法

现假定 $f(x)$ 、 $g_i(x)$ 和 $h_j(x)$ ($i=1,2,\dots,p; j=1,2,\dots,q$) 具有一阶连续偏导数。设 x^0 是非线性规划的一个可行解，它满足所有约束。现考虑某一不等式约束条件 $g_i(x) \geq 0$ ， x^0 满足它有两种可能：

其一为 $g_i(x^0) > 0$ ，对 x^0 点的微小摄动，该约束仍然成立。因而这一约束对 x^0 点的微小摄动不起限制作用，从而称这个约束条件是 x^0 点的**无效约束 (或不起作用约束)**；

其二是 $g_i(x^0) = 0$ ，这时 x^0 点处于该约束条件形成的可行域边界上，只要 x^0 有摄动，该约束就发生变化。因此，该约束对 x^0 的摄动起到了限制作用，故称这个约束是 x^0 点的**有效约束 (或起作用约束)**。显然，等式约束对所有可行点来说都是起作用约束。

约束非线性规划的解法

假定 x^0 是非线性规划 (2.1)-(2.2) 的一个可行点, 现考虑此点的某一方向 P , 若存在实数 $\lambda_0 > 0$, 使对任意 $\lambda \in [0, \lambda_0]$ 均有

$$x^0 + \lambda P \in K,$$

就称方向 P 是 x^0 点的一个可行方向。根据梯度的性质, 在可行点 x^0 处的曲面函数的梯度 $\nabla g_i(x^0)$ 方向一定指向 K 内, 即可行方向与曲面 $g_i(x) = 0$ 本身以及曲面函数的梯度 $\nabla g_i(x^0)$ 都在可行点 x^0 处的切平面的同侧。因此, 若 P 是可行点 x^0 处的任一可行方向, 则对该点的所有有效约束 $g_i(x) \geq 0$, 均有

$$\nabla g_i(x^0)^\top P \geq 0, \quad i \in I,$$

其中 I 为这个点所有有效约束下标的集合。

约束非线性规划的解法

另一方面，由泰勒公式

$$g_i(x^0 + \lambda P) = g_i(x^0) + \lambda \nabla g_i(x^0)^\top P + o(\lambda),$$

对所有有效约束，当 $\lambda > 0$ 足够小时，只要

$$\nabla g_i(x^0)^\top P > 0, \quad i \in I, \quad (2.8)$$

就有 $g_i(x^0 + \lambda P) \geq 0, i \in I$ 。此外，对 x^0 点的无效约束，由约束函数的连续性，当 $\lambda > 0$ 足够小时亦有上式成立。从而只要方向 P 满足 (2.8)，即可保证它是 x^0 点的可行方向。

约束非线性规划的解法

考虑非线性规划的某一可行点 x^0 ，对该点的任一方向 P 来说，若存在实数 $\lambda'_0 > 0$ ，使对任意 $\lambda \in [0, \lambda'_0]$ 均有

$$f(x^0 + \lambda P) < f(x^0),$$

就称方向 P 为 x^0 点的一个下降方向。将目标函数 $f(x)$ 在点 x^0 处作一阶泰勒展开，可知满足条件

$$\nabla f(x^0)^\top P < 0$$

的方向 P 必为 x^0 点的下降方向。如果方向 P 既是 x^0 点的可行方向，又是这个点的下降方向，就称它是该点的可行下降方向。假如 x^0 点不是极小点，继续寻优时的搜索方向就应从该点的可行下降方向中去找。显然，若某点存在可行下降方向，它就不会是极小点。另一方面，若某点为极小点，则在该点不存在可行下降方向。

约束非线性规划的解法

定理 2.11

设 x^* 是非线性规划 (2.1)-(2.2) 的一个局部最优解, 目标函数 $f(x)$ 在 x^* 处可微, 而且当 $i \in I$ 时 $g_i(x)$ 在 x^* 处可微, 当 $i \notin I$ 时 $g_i(x)$ 在 x^* 处连续. 则在 x^* 点不存在可行下降方向, 从而不存在向量 P 同时满足

$$\begin{cases} \nabla f(x^*)^\top P < 0 \\ \nabla g_i(x^*)^\top P > 0, \quad i \in I \end{cases} \quad (2.9)$$

这个定理显然是成立的。事实上, 若存在满足 (2.9) 的方向 P , 则沿该方向搜索可找到更好的点, 从而与 x^* 为局部最优解的假设矛盾。满足 (2.9) 的方向 P , 与点 x^* 处目标函数负梯度方向的夹角为锐角, 与点 x^* 处有效约束的梯度方向的夹角也为锐角。

K-T 条件

一. 库恩—塔克条件 (简称 K-T 条件)

假定 x^* 是非线性规划的局部最优解, 该点可能位于可行域的内部, 也可能处于可行域的边界上。若为前者, 这事实上是个无约束问题, x^* 必满足条件 $\nabla f(x^*) = 0$ 。现在我们来讨论后一种情形:

不失一般性, 设 x^* 位于第一个约束条件形成的可行域边界上, 即第一个约束条件是 x^* 点的有效约束 $g_1(x^*) = 0$ 。若 x^* 是局部最优解, 假定向量 $\nabla g_1(x^*)$ 和 $\nabla f(x^*)$ 皆不为零, 则 $\nabla g_1(x^*)$ 必与 $\nabla f(x^*)$ 在一条直线上且方向相反, 否则必有方向 P 使 (2.9) 成立, 即与有效约束的梯度方向的夹角成锐角, 而与目标函数的梯度方向成钝角, 即在该点就一定存在可行下降方向, 这与该点是局部最优解矛盾。因此, 在上述条件下, 存在实数 $\lambda_1 \geq 0$ 使得

$$\nabla f(x^*) - \lambda_1 \nabla g_1(x^*) = 0.$$

K-T 条件

若 x^* 点有两个有效约束，例如说有 $g_1(x^*) = 0$ 和 $g_2(x^*) = 0$ 。在这种情况下， $\nabla f(x^*)$ 必处于 $\nabla g_1(x^*)$ 和 $\nabla g_2(x^*)$ 的夹角之内。否则，必有方向 P 与 $\nabla g_1(x^*)$ 和 $\nabla g_2(x^*)$ 的夹角均成锐角，而与目标函数的梯度方向成钝角，即在 x^* 点就一定存在可行下降方向，这与该点是局部最优解矛盾。由此可见，如果 x^* 是局部最优解，而且 x^* 点的有效约束条件的梯度 $\nabla g_1(x^*)$ 和 $\nabla g_2(x^*)$ 线性无关，则可将 $\nabla f(x^*)$ 表示成 $\nabla g_1(x^*)$ 和 $\nabla g_2(x^*)$ 的非负线性组合。也就是说，在这种情况下存在实数 $\lambda_1 \geq 0$ 和 $\lambda_2 \geq 0$ ，使得

$$\nabla f(x^*) - \lambda_1 \nabla g_1(x^*) - \lambda_2 \nabla g_2(x^*) = 0.$$

如上类推，可以得到

$$\nabla f(x^*) - \sum_{i \in I} \lambda_i \nabla g_i(x^*) = 0.$$

K-T 条件

为了把无效约束也包括进上式中，增加条件

$$\begin{cases} \lambda_i g_i(x^*) = 0, \\ \lambda_i \geq 0. \end{cases}$$

当 $g_i(x^*) = 0$ 时， λ_i 可不为零；当 $g_i(x^*) \neq 0$ 时，必有 $\lambda_i = 0$ 。如此即可得到著名的库恩—塔克条件，简称为 K-T 条件。

库恩—塔克条件是非线性规划领域中最重要理论成果之一，是确定某点为最优点的必要条件。只要是最优点，就必须满足这个条件。但一般说它并不是充分条件，因而满足这个条件的点不一定就是最优点（对于凸规划，它既是最优点存在的必要条件，同时也是充分条件）。

K-T 条件

现将库恩—塔克条件叙述如下：

设 x^* 是非线性规划 (2.1)-(2.2) 的局部最优解，而且在 x^* 点的各有效约束的梯度线性无关，则存在向量 $\Lambda^* = (\lambda_1^*, \lambda_2^*, \dots, \lambda_p^*)^\top$ ，使下述条件成立

$$\begin{cases} \nabla f(x^*) - \sum_{i=1}^p \lambda_i^* \nabla g_i(x^*) = 0 \\ \lambda_i^* g_i(x^*) = 0, \quad i = 1, 2, \dots, p \\ \lambda_i^* \geq 0, \quad i = 1, 2, \dots, p \end{cases} \quad (2.10)$$

条件 (2.10) 常简称为 **K-T 条件**。满足这个条件的点 (它当然也满足非线性规划的所有约束条件) 称为 **库恩—塔克点 (或 K-T 点)**。

K-T 条件

为了得出非线性规划 (2.1)-(2.2) 的库恩—塔克条件，我们用

$$\begin{cases} h_j(x) \geq 0, \\ -h_j(x) \geq 0 \end{cases}$$

代替约束条件 $h_j(x) = 0$ ，这样即可使用条件 (2.10)，从而得到这时的库恩—塔克条件如下

K-T 条件

定理 2.13 (必要条件)

设 x^* 是非线性规划问题 (2.1)-(2.2) 的局部最优解, 而且 x^* 点的所有起作用约束的梯度 $h_j(x^*)$ ($j = 1, 2, \dots, q$) 和 $g_i(x^*)$ ($i = 1, 2, \dots, p$) 线性无关, 则存在向量

$$\Lambda^* = (\lambda_1^*, \lambda_2^*, \dots, \lambda_p^*)^\top, \quad \Gamma^* = (\gamma_1^*, \gamma_2^*, \dots, \gamma_q^*)^\top$$

使下述条件成立

$$\begin{cases} \nabla f(x^*) - \sum_{i=1}^p \lambda_i^* \nabla g_i(x^*) - \sum_{j=1}^q \gamma_j^* \nabla h_j(x^*) = 0 \\ \lambda_i^* g_i(x^*) = 0, \quad i = 1, 2, \dots, p \\ \lambda_i^* \geq 0, \quad i = 1, 2, \dots, p \end{cases} \quad (2.11)$$

K-T 条件

当然，满足条件 (2.11) 的点也称为库恩—塔克点。在条件 (2.10) 和 (2.11) 中， $\lambda_1^*, \lambda_2^*, \dots, \lambda_p^*$ 以及 $\gamma_1^*, \gamma_2^*, \dots, \gamma_q^*$ 称为广义拉格朗日 (Lagrange) 乘子。

定理 2.14 (充分条件)

若 x 满足 K-T 条件，则 x 必为凸规划的局部最优解，进而为整体最优解。

定理 2.13 和定理 2.14 给出了非线性规划问题的最优解应满足的充分条件和必要条件，二者合称为非线性规划基本定理。如果 x 为凸规划的 (局部、整体) 最优解 $\Leftrightarrow x$ 满足 K-T 条件。

K-T 条件

例. 用库恩—塔克条件解非线性规划

$$\begin{cases} \min f(x) = (x-3)^2, \\ 0 \leq x \leq 5 \end{cases}$$

解: 先将该非线性规划问题写成以下形式

$$\begin{cases} \min f(x) = (x-3)^2, \\ g_1(x) = x \geq 0, \\ g_2(x) = 5-x \geq 0 \end{cases}$$

写出其目标函数和约束函数的梯度

$$\nabla f(x) = 2(x-3), \quad \nabla g_1(x) = 1, \quad \nabla g_2(x) = -1.$$



K-T 条件

对第一个和第二个约束条件分别引入广义拉格朗日乘子 λ_1^* 和 λ_2^* ,
设 K-T 点为 x^* , 则可写出该问题的 K-T 条件如下

$$\begin{cases} 2(x^* - 3) - \lambda_1^* + \lambda_2^* = 0, \\ \lambda_1^* x^* = 0, \\ \lambda_2^* (5 - x^*) = 0, \\ \lambda_1^*, \lambda_2^* \geq 0. \end{cases}$$



K-T 条件

为解上述方程组，考虑以下几种情形：

- (1) 令 $\lambda_1^* \neq 0, \lambda_2^* \neq 0$ ，无解。
- (2) 令 $\lambda_1^* \neq 0, \lambda_2^* = 0$ ，解得 $x^* = 0, \lambda_1^* = -6$ ，不是 K-T 点。
- (3) 令 $\lambda_1^* = 0, \lambda_2^* \neq 0$ ，解得 $x^* = 5, \lambda_2^* = -4$ ，不是 K-T 点。
- (4) 令 $\lambda_1^* = \lambda_2^* = 0$ ，解得 $x^* = 3$ ，此为 K-T 点，其目标函数值为 $f(x^*) = 0$ 。

由于该非线性规划问题为凸规划，故 $x^* = 3$ 就是其全局极小点。该点是可行域的内点，它也可直接由梯度等于零的条件求出。

利用 K-T 条件 (包括拉格朗日乘子法) 求解约束非线性规划问题是有局限性的，故需寻找其他方法。

惩罚函数法

二. 惩罚函数法

求解约束非线性规划问题的一般思路是将其转化为等价的无约束非线性规划问题，一般做法如下：

1. 构造新函数

$$\begin{aligned} Q(x, M) &= f(x) + M \left[\sum_{i=1}^p \varphi(g_i(x)) + \sum_{j=1}^q \varphi(h_j^2(x)) \right] \\ &= f(x) + M \left[\sum_{i=1}^p (\min(0, g_i(x)))^2 + \sum_{j=1}^q \varphi(h_j^2(\mathbf{x})) \right] \end{aligned}$$

其中 M 是个充分大的正数。

惩罚函数法

当 $x \in K$ 时, 有 $\min(0, g_i(x)) = 0, h_j^2(x) = 0$, 故

$$Q(x, M) = f(x) + M \cdot 0 = f(x);$$

当 $x \notin K$ 时, 有 $\min(0, g_i(x)) = g_i(x), h_j^2(x) = 0$ 不一定成立, 故

$$Q(x, M) > f(x) + 0 = f(x).$$

综上

$$Q(x, M) \begin{cases} = f(x), & x \in K \\ > f(x), & x \notin K. \end{cases}$$

惩罚函数法

2. 构造无条件极值问题 $\min Q(x, M)$, 并解得极值点 x^*

若 $x \notin K$, 则根据上述分析知

$$\sum_{i=1}^p (\min(0, g_i(x^*)))^2 + \sum_{j=1}^q h_j^2(x^*) = \sum_{i=1}^p g_i^2(x^*) + \sum_{j=1}^q h_j^2(x^*) > 0.$$

由于 M 是个充分大的正数, 故函数 $Q(x, M)$ 的值是一个充分大的正数, Q 不可能取得最小值 (受到惩罚), 因此称 $Q(x, M)$ 为惩罚函数, 并称

$$M \left[\sum_{i=1}^p (\min(0, g_i(x^*)))^2 \right]$$

为惩罚项, M 为惩罚因子。

惩罚函数法

换言之, Q 要取得最小值, 须有 $x \in K$ 。此时, 在一定的允许误差下, 可将 x^* 作为 NLP 的 (近似的) 最优解。更进一步地, 有如下结论:

定理 2.15

若 Q 的极值点 $x \in K$, 则 x 必为 NLP 的最优解。

惩罚函数的**基本思想**: 取某正数 $M = M_1$, 求解无条件极值问题 $\min Q(x, M_1)$, 假设其极值点为 x' 。若 $x' \in K$, 则由定理 2.15 知, x' 即为 (NLP) 的最优解。否则, 令 $M = M_2 := 10M_1$, 重复以上步骤。

惩罚函数法

算法步骤:

步骤 1. 令 $M := M_1 > 0$, 允许误差 $\varepsilon > 0$, $k := 1$

步骤 2. 求解无条件极值问题 $\min Q(x, M_1)$, 设得其极值点 x^k

步骤 3. 若 $g_i(x^k) \leq \varepsilon, |h_j(x^k)| \leq \varepsilon, (i = 1, 2, \dots, p; j = 1, 2, \dots, q)$,
则 x^k 即为 NLP 的近似最优解, 结束步骤。否则, 转步骤 4

步骤 4. 令 $M = M_{k+1} := 10M_k$, 转步骤 2

案例一：容器的设计问题

问题背景：某公司专门生产储蓄容器，订货合同要求该公司制造一种敞口的长方体容器，容器恰好为 12 立方米，该容器的底必须为正方形，容器总重量不超过 68 公斤。已知用做容器四壁的材料为每平方米 10 元，重 3 公斤，用做容器底的材料每平方米 20 元，重 2 公斤。试建立制造该容器**费用**最小的最优化模型

模型建立：该容器底边长和高分别为 x_1, x_2 ，以容器的费用为目标函数，则问题的数学模型为

$$\begin{aligned} \min \quad & f(\mathbf{x}) = 40x_1x_2 + 20x_1^2 \\ \text{s.t.} \quad & \begin{cases} x_1^2x_2 = 12 \\ 12x_1x_2 + 2x_1^2 \leq 68 \\ x_1 \geq 0, x_2 \geq 0 \end{cases} \end{aligned}$$

案例二：地址问题

问题背景：某特大城市拟新建一个民用机场，在选址与可行性研究阶段，提出要在 A, B, C, D, E, F 6 个卫星城市都得到统筹兼顾的原则下，使 6 个城市**客运费最低**作为选址目标，相关数据如表所示

案例二：地址问题

卫星城	平面坐标位置 (x,y)	货运量/万吨 (W_i)
A	(40,200)	40
B	(160,210)	10
C	(250,160)	20
D	(220,80)	30
E	(100,40)	20
F	(30,100)	10

说明

(1) $x+y \geq 250$ 处于高山，不适合建机场

(2) $(x-120)^2 + (y-160)^2 \leq 400$ 处在最大湖，不准建机场

试构建机场选址的 NLP 模型

案例二：地址问题

模型求解： 设 (x,y) 为机场选址的位置坐标，总运费极小化的目标函数 $f(x,y)$ 由 6 个卫星城市的货运量 (吨/千米) 之和决定，即

$$\begin{aligned}\min f(x,y) &= W_A L_A + W_B L_B + W_C L_C + W_D L_D + W_E L_E + W_F L_F \\ &= 40\sqrt{(x-40)^2 + (y-200)^2} + 10\sqrt{(x-160)^2 + (y-210)^2} \\ &\quad + 20\sqrt{(x-250)^2 + (y-160)^2} + 30\sqrt{(x-220)^2 + (y-80)^2} \\ &\quad + 20\sqrt{(x-100)^2 + (y-40)^2} + 10\sqrt{(x-30)^2 + (y-100)^2}\end{aligned}$$

约束条件如下

$$\begin{cases} x+y < 250 \\ (x-120)^2 + (y-160)^2 > 400 \\ x \geq 0, \quad y \geq 0 \end{cases}$$

可以看出上式中目标函数和约束条件都有非线性函数

案例三

案例三：

● 2022 ICM (Problem E: “Forestry for Carbon Sequestration”)

问题描述：国际碳管理合作组织（ICM）成立旨在为全球森林管理者制定管理指南，指导其合理利用和管理森林资源。鉴于森林兼具碳封存、生态保护、社会文化等多重价值，请构建决策模型以量化森林及其林产品随时间推移可封存的二氧化碳总量，并平衡综合效益。确定最有效的固碳管理计划

案例三

问题分析:

1. 决策变量定义:

$x_{i,t}$: 第 t 年树种 i 的种植面积比例

$y_{i,t}$: 第 t 年树种 i 的采伐量 (m^3/km^2)

τ_i : 树种 i 的轮伐周期 (年)

其中 $i \in \{\text{橡树, 松树, 桦树}\}$, $t = 1, 2, \dots, 50$



案例三

2. 目标函数：净碳固存最大化

$$\max \sum_{t=1}^{50} e^{-rt} \left[\underbrace{\sum_i C_{\text{grow}}(i,t)}_{\text{生长固碳}} - \underbrace{\sum_i C_{\text{harvest}}(i,t)}_{\text{采伐碳排放}} \right]$$

- 碳生长模型 (Chapman-Richards 方程):

$$C_{\text{grow}}(i,t) = k_i(1 - e^{-b_i t})^{c_i} \cdot x_{i,t}$$

- 采伐碳排放:

$$C_{\text{harvest}}(i,t) = \alpha_i y_{i,t} + \beta_i (y_{i,t})^{1.5}$$

- 贴现因子: $r = 0.03$ (年贴现率)

案例三

3. 约束条件

(1) 土地面积约束

$$\sum_i x_{i,t} = 1,$$

$$|x_{i,t} - x_{i,t-1}| \leq 0.1 \quad (\text{年际变化限制})$$

(2) 轮伐周期逻辑

$$y_{i,t} = \begin{cases} 0 & t \neq k\tau_i \\ \gamma_i A_i(t) & t = k\tau_i \end{cases}$$

其中 $A_i(t) = \int_{t-\tau_i}^t C_{\text{grow}}(i,s) ds$

案例三

(3) 经济可持续约束

$$\sum_t e^{-rt} [p_i y_{i,t} - c_{\text{manage}}] \geq 0$$

- 木材价格: $p_{\text{橡树}} = 150$ 美元/ m^3 , $p_{\text{松树}} = 100$ 美元/ m^3 , $p_{\text{桦树}} = 120$ 美元/ m^3 ,
- 管理成本: $c_{\text{manage}} = 200$ 美元/ $\text{km}^2/\text{年}$

(4) 生物多样性保护

$$0.3 \leq \frac{1}{50} \sum_t \text{Shannon}(t) \leq 0.7,$$

其中香农多样性指数为 $\text{Shannon}(t) = \sum_i x_{i,t} \ln(x_{i,t})$

(5) 采伐量物理限制

$$0 \leq y_{i,t} \leq 0.8 \times C_{\text{grow}}(i,t) \quad (\text{最大可持续产量})$$

作业

1. 某电力公司每天最多可以生产 250 万度电，来自高需求（高峰区）的客户和低需求（非高峰区）的客户的电力需求（单位：百万度）由下列公式确定

$$\text{高需求} : 5.8 - 0.06p_h + 0.005p_l,$$

$$\text{低需求} : 3 - 0.11p_l + 0.008p_h.$$

可变量 p_l 为低需求期每度电的价格， p_h 为高需求期每度电的价格。列出公式并求解问题的非线性规划模型，以求出能最大化收入的价格结构

作业

2. E 市公安部门把城市分成 4 个区。该部门每天每次换班分配 20 个可用的巡逻警车到每个区。在值班期间公安部门打算分配巡逻车到每个区，以追求最低的犯罪率，同时对报警电话的平均响应时间不超过 10 分钟。随着越多的巡逻车被分配到一个区域，这一区域的犯罪率和响应时间也随着减少，但是根据下列公式，减少的比率在下降

$$y = a + (b/x)$$

作业

日犯罪率 (每 1000 人的犯罪次数) 和响应时间 (分钟) 的参数 a 和 b 如下表所示

	犯罪率		响应时间 (分钟)	
	a	b	a	b
1	0.24	0.15	4	11
2	0.37	0.21	8	8
3	0.21	0.12	6	10
4	0.48	0.30	3	9

列出公式并求解本问题的非线性规划模型, 以求出能使总犯罪率最小的分配到每个区域的巡逻警车的数量。

作业

3. 某工厂向用户提供发动机，按合同规定其交货数量和日期是：第一季度末交 40 台，第二季末交 60 台，第三季末交 80 台。工厂的最大生产能力为每季 100 台，每季的生产费用是 $f(x) = 50x + 0.2x^2$ (元)，此处 x 为该季生产发动机的台数。若工厂生产的多，多余的发动机可移到下季向用户交货，这样工厂就需支付存贮费，每台发动机每季的存贮费为 4 元。问该厂每季应生产多少台发动机，才能既满足交货合同，又使工厂所花费的费用最少（假定第一季度开始时发动机无存货）

谢谢！

